



แอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์

Mobile Application for Classifying Fruits and Vegetables using Artificial Intelligence

นภสร พุทธเจริญ¹, ชาลินี แซ่ลี² และวรัทภาพ วัชรสุวรรณ³

¹noppasorn.put@ku.th, ²chalineesa@ku.th, ³warattapop.t@ku.th

บทคัดย่อ

โครงการนี้มีวัตถุประสงค์ในการออกแบบและพัฒนาแอปพลิเคชันมือถือที่สามารถจำแนกผักและผลไม้โดยใช้ปัญญาประดิษฐ์ โดยการนำเทคโนโลยีการประมวลผลภาพมาผนวกกับการเรียนรู้ของเครื่อง (Machine Learning) โดยเฉพาะการใช้โครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) เพื่อเพิ่มความแม่นยำและประสิทธิภาพในการระบุชนิดของผักและผลไม้ แอปพลิเคชันนี้จะช่วยให้ผู้ใช้สามารถถ่ายภาพหรืออัปโหลดภาพของผักและผลไม้เพื่อให้ระบบทำการจำแนกประเภทและแสดงข้อมูลที่เกี่ยวข้อง เช่น เทคนิคการเลือกซื้อ และวิธีการเก็บรักษา นอกจากนี้ ผลลัพธ์จากโครงการนี้ยังสามารถนำไปพัฒนาต่อยอดเพื่อสนับสนุนด้านสุขภาพและส่งเสริมความรู้เกี่ยวกับการบริโภคที่เหมาะสมได้

คำสำคัญ: การประมวลผลภาพ, การเรียนรู้ของเครื่อง, โครงข่ายประสาทเทียมแบบคอนโวลูชัน, ปัญญาประดิษฐ์, แอปพลิเคชันมือถือ

Abstract

This project aims to design and develop a mobile application for classifying fruits and vegetables using artificial intelligence. The application integrates image processing technology with machine learning, specifically utilizing Convolutional Neural Networks (CNNs) to enhance the accuracy and efficiency of fruit and vegetable classification. Users can take or upload photos of fruits and vegetables for the system to classify and display relevant information, such as selection tips and storage methods. Furthermore, the results of this project can be further developed to support health initiatives and promote knowledge on proper consumption.

Keywords: Image Processing, Machine Learning, Convolutional Neural Network, Artificial Intelligence, Mobile Application

1. บทนำ (Introduction)

เทคโนโลยีการประมวลผลภาพและการเรียนรู้ของเครื่อง (Machine Learning) ที่กำลังพัฒนาอย่างรวดเร็ว โดยเฉพาะในด้านการจำแนกประเภทและการจดจำภาพ การพัฒนาแอปพลิเคชันจำแนกผักและผลไม้ด้วยเทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) มีจุดเริ่มต้นจากการสังเกตปัญหาที่เกิดขึ้นในชีวิตประจำวันของผู้บริโภค โดยเฉพาะในตลาดและซูเปอร์มาร์เก็ต ผู้บริโภคมักประสบปัญหาในการระบุชนิดของผักและผลไม้ที่ต้องการได้อย่างถูกต้องเนื่องจากความหลากหลายของชนิด อีกทั้งยังมีข้อจำกัดในการให้ข้อมูลที่ถูกต้องเกี่ยวกับเทคนิคการเลือกซื้อ การเก็บรักษา และวิธีการทำอาหาร ส่งผลต่อการตัดสินใจของผู้บริโภค

เพื่อแก้ไขปัญหานี้ แอปพลิเคชันที่ใช้เทคโนโลยีการประมวลผลภาพและการเรียนรู้ของเครื่องจะช่วยให้ผู้ใช้สามารถถ่ายภาพผักและผลไม้ผ่านกล้องสมาร์ทโฟนและนำภาพเหล่านั้นมาประมวลผลเพื่อให้ข้อมูลที่ถูกต้องเกี่ยวกับชนิดของผักและผลไม้ที่สนใจ รวมถึงเป็นการส่งเสริมความรู้และความเข้าใจเกี่ยวกับการเลือกซื้อผักและผลไม้ที่มีคุณภาพในกลุ่มผู้บริโภคภายในประเทศและผู้บริโภคต่างชาติ



แอปพลิเคชันนี้ยังช่วยให้ผู้ใช้ได้เรียนรู้เกี่ยวกับผักและผลไม้ไทย โดยได้คัดเลือกชนิดที่มีความนิยมในตลาดไทย 9 ชนิด ได้แก่ มะระขี้นก, กะหล่ำปลี, กะหล่ำดอก, หัวไชเท้า, น้อยหน่า, แก้วมังกร, เงาะ, สลัด, และมังคุด ซึ่งถือเป็นผักและผลไม้ที่มีลักษณะหลากหลาย นอกจากนี้ยังเป็นที่น่าสนใจในหมู่นักท่องเที่ยวต่างชาติ การรวบรวมข้อมูลและลักษณะเฉพาะของผลไม้แต่ละชนิดจากแหล่งข้อมูลที่เชื่อถือได้จะทำให้ผู้บริโภคได้รับข้อมูลที่ครบถ้วนและถูกต้องในการเลือกซื้อ (Toast to Thailand, 2021).

นอกจากนี้ ผักและผลไม้ที่มีลักษณะคล้ายกัน ซึ่งอาจทำให้โมเดลเกิดความสับสนในการจำแนก ยกตัวอย่าง กะหล่ำดอกและน้อยหน่า ทั้งสองชนิดมีลักษณะผิวขรุขระหรือเป็นปุ่ม ๆ ซึ่งสามารถทำให้โมเดลจำแนกผิดพลาดระหว่างกันได้ แต่มนุษย์สามารถแยกแยะได้จากลักษณะของรูปร่างที่แตกต่างกัน เช่น กะหล่ำดอกมีลักษณะเป็นกลุ่มของดอกไม้ที่มีสีขาว และมีรูปร่างเป็นทรงกลมป้อม ในขณะที่น้อยหน่าจะมีลักษณะเป็นผลไม้ที่มีผิวหยาบและมีรูปร่างคล้ายทรงกรวยหรือกลมแบน และมีสีเขียวหรือเหลืองอ่อนเมื่อสุก

การที่มนุษย์สามารถแยกแยะความแตกต่างของผักและผลไม้ที่มีลักษณะคล้ายกันได้ เกิดจากประสบการณ์และการเรียนรู้จากการสัมผัสและการสังเกตในรายละเอียดที่แตกต่างกัน เช่น รูปร่าง สี ผิวสัมผัส และขนาด ซึ่งทำให้มนุษย์สามารถแยกแยะได้แม้ผักหรือผลไม้จะมีลักษณะภายนอกคล้ายกัน ขณะที่โมเดลการเรียนรู้ของเครื่องยังต้องการการพัฒนาเพิ่มเติมเพื่อให้สามารถรับรู้และแยกแยะลักษณะเหล่านี้ได้ โดยการฝึกโมเดลด้วยข้อมูลจำนวนมากและหลากหลาย ซึ่งจะช่วยเพิ่มความสามารถในการจำแนกผักและผลไม้ที่มีลักษณะคล้ายคลึงกันให้มีความถูกต้องมากขึ้น

ดังนั้น ผู้จัดทำจึงพัฒนาแอปพลิเคชันจำแนกผักและผลไม้ด้วยเทคโนโลยีการเรียนรู้ของเครื่อง จึงมีความสำคัญทั้งในด้านการส่งเสริมความรู้และความเข้าใจในการเลือกซื้อผักและผลไม้ที่มีคุณภาพสำหรับผู้บริโภคในประเทศและชาวต่างชาติ ตลอดจนเป็นการนำเทคโนโลยีสมัยใหม่มาปรับใช้เพื่อพัฒนาประสบการณ์ในการเพิ่มการตัดสินใจในการเลือกซื้อที่ดียิ่งขึ้น

2. วัตถุประสงค์ (Objectives)

- 2.1 เพื่อพัฒนาแบบจำลองสำหรับจำแนกผักและผลไม้ โดยประยุกต์ใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) เพื่อให้สามารถจำแนกชนิดของผักและผลไม้ได้
- 2.2 เพื่อพัฒนาแอปพลิเคชันที่สามารถให้ข้อมูลที่เป็นประโยชน์เกี่ยวกับผักและผลไม้ เช่น เทคนิคในการเลือกซื้อผักและผลไม้ วิธีการเก็บรักษา และขั้นตอนการทำอาหาร โดยมุ่งเน้นการเพิ่มความสะดวกและความรู้ให้แก่ผู้ใช้งานในการเลือกซื้อและบริโภคอย่างมีประสิทธิภาพ

3. ขอบเขตของโครงการ (Scope of the Project)

ในการพัฒนาคอมพิวเตอร์แอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์ ได้แบ่งขอบเขตของโครงการ ดังนี้

3.1 การพัฒนาโมเดล

การศึกษาโครงสร้างที่ใช้สำหรับการพัฒนาโมเดลการจำแนกผักและผลไม้ คือ สถาปัตยกรรม Convolutional Neural Network (CNN) โดยนำมาปรับแต่งโครงสร้างและพารามิเตอร์ของโมเดลให้เหมาะสมกับข้อมูลของการจำแนกประเภทอย่างมีประสิทธิภาพ



3.2 ชุดข้อมูลที่ใช้ในการพัฒนาโมเดล แอปพลิเคชันถูกพัฒนาให้สามารถจำแนกผักและผลไม้ได้ทั้งหมด 9 ชนิด แบ่งออกเป็น ผัก 4 ชนิด ได้แก่ มะระขี้นก, ดอกกะหล่ำ, กะหล่ำปลี, หัวไชเท้าขาว และผลไม้ 5 ชนิด ได้แก่ น้อยหน่า, แก้วมังกร, เงาะ, สละ, มังคุด

3.3 การเตรียมข้อมูลภาพ

3.3.1 ข้อมูลภาพที่ใช้ในการฝึกสอนโมเดลจะได้รับการทำ **Normalization** เพื่อปรับค่าของข้อมูลภาพให้อยู่ในช่วงที่เหมาะสมสำหรับการประมวลผล ซึ่งช่วยลดการแปรปรวนของข้อมูล ทำให้การประมวลผลของโมเดลมีประสิทธิภาพยิ่งขึ้น

3.3.2 มีการทำ **Data Augmentation** ด้วยเทคนิคการหมุนภาพ (rotation), การครอบภาพ (cropping) เพื่อเพิ่มจำนวนภาพที่ใช้ในการฝึกสอน และทำให้โมเดลเรียนรู้จากข้อมูลที่หลากหลาย ป้องกันการ overfitting

3.4 การแบ่งข้อมูลสำหรับการฝึกและการทดสอบ

3.4.1 ข้อมูลที่นำมาใช้ได้รับการทำความสะอาดและแบ่งออกเป็นอัตราส่วน 80:20 โดยมีภาพรวมทั้งหมด 9,466 ภาพ แบ่งเป็นข้อมูลการฝึกสอน (Training Data) จำนวน 7,572 ภาพ และข้อมูลการทดสอบ (Test Data) จำนวน 1,894 ภาพ

3.4.2 ใช้วิธีการ **Cross Validation** เพื่อตรวจสอบความสามารถของโมเดลอย่างละเอียด ช่วยให้เห็นภาพรวมของความถูกต้องและประสิทธิภาพของโมเดลในข้อมูลที่แตกต่างกัน โดยใช้วิธีการแบ่งข้อมูลแบบ k-fold cross-validation โดยผู้วิจัยได้แบ่งชุดข้อมูลจำนวน 5 ชุดข้อมูล เพื่อใช้สำหรับสลับเป็นชุดเรียนรู้ และชุดการทดสอบ

3.5 การประเมินประสิทธิภาพของโมเดล ใช้วิธีการ **Confusion Matrix** เพื่อแสดงผลลัพธ์ของการทำนายโมเดลในรูปแบบของตารางที่ช่วยให้เห็นภาพรวมของความแม่นยำในการทำนาย ได้แก่ จำนวนตัวอย่างที่ทำนายถูกต้อง (True Positive และ True Negative) และตัวอย่างที่ทำนายผิดพลาด (False Positive และ False Negative)

- ค่าความแม่นยำ (Precision)
- ค่าความระลึก (Recall)
- ค่าความถูกต้อง (Accuracy)
- F1 Score

3.6 ข้อจำกัดของโมเดล (Limitations)

3.6.1 เนื่องจากจำนวนข้อมูลที่ไม่สมดุลในแต่ละคลาส ซึ่งอาจส่งผลต่อความแม่นยำของการจำแนกประเภท โดยเฉพาะคลาสที่มีจำนวนข้อมูลน้อยกว่า

3.6.2 ข้อมูลภาพที่ใช้ในการพัฒนาระบบมาจากแหล่งที่ไม่สามารถครอบคลุมทุกลักษณะของผักและผลไม้ได้ เช่น ความหลากหลายของสายพันธุ์ อาจส่งผลให้โมเดลไม่สามารถจำแนกผลไม้หรือผักที่มีลักษณะเฉพาะที่ยังไม่ได้เห็นในข้อมูลที่ฝึก

3.7 Mobile Application ได้แบ่งส่วนการทำงานของระบบดังนี้

3.7.1 ขอบเขตของผู้ใช้ (User)

1. สามารถสมัครสมาชิกและเข้าสู่ระบบได้
2. สามารถใช้กล้องบนสมาร์ทโฟนในการถ่ายภาพหรืออัปโหลดรูปภาพของผักและผลไม้ได้
3. สามารถดูข้อมูลของผักและผลไม้แต่ละชนิดได้ เช่น เทคนิคในการเลือกซื้อ ประโยชน์ วิธีการเก็บรักษา และเมนูอาหาร
4. สามารถเลือกรายการอาหารจากผักหรือผลไม้ ได้แก่ ชื่ออาหาร รายละเอียดของอาหาร รวมถึงลิงค์เว็บไซต์เพื่อดูขั้นตอนการอาหาร
5. สามารถแก้ไขข้อมูลส่วนตัวได้ เช่น การแก้ไขชื่อผู้ใช้งาน (Username) และรูปภาพโปรไฟล์
6. สามารถแจ้งข้อบกพร่องหรือปัญหาที่พบในการใช้งานแอปพลิเคชันได้โดยตรงผ่านระบบ

3.7.2 ขอบของผู้ดูแลระบบ (Administrator)


1. สามารถเข้าสู่ระบบได้
2. สามารถดูผู้ใช้งานได้
3. สามารถเพิ่ม ลบ และแก้ไขข้อมูลที่เกี่ยวข้องกับผักและผลไม้ได้
4. สามารถเพิ่ม ลบ และแก้ไขข้อมูลรายการอาหารของผักและผลไม้ได้
5. สามารถเก็บข้อมูลปัญหาการใช้งานของแอปพลิเคชันที่ผู้ใช้งานแจ้งเข้ามา

4. การทบทวนวรรณกรรม (Literature Review)

ผู้จัดทำได้ทำการศึกษาแนวคิดและทฤษฎีที่เกี่ยวข้อง งานวิจัยที่เกี่ยวข้อง และเครื่องมือที่ใช้ในการพัฒนาระบบ ดังนี้

4.1 แนวคิดและทฤษฎีที่เกี่ยวข้อง

4.1.1 โครงข่ายประสาทเทียมแบบคอนโวลูชัน (CNNs)




ภาพที่ 1 Convolutional Neural Network Architecture

Convolutional Neural Network (CNN) หรือ โครงข่ายประสาทเทียมแบบคอนโวลูชัน เป็นโครงข่ายประสาทเทียมหนึ่งในกลุ่ม bio-inspired โดยที่ CNN จะจำลองการมองเห็นของมนุษย์ที่มองพื้นที่เป็นที่ย่อยๆ และนำกลุ่มของพื้นที่ย่อยๆ มาผสานกัน เพื่อดูว่าสิ่งที่เห็นอยู่เป็นอะไร การมองพื้นที่ย่อยของมนุษย์จะมีการแยกคุณลักษณะ (feature) ของพื้นที่ย่อยนั้น เช่น ลายเส้น และการ



ตัดกันของสี่ ซึ่งการที่มนุษย์รู้ว่าพื้นที่ตรงนี้เป็นเส้นตรงหรือสี่เหลี่ยม เพราะมนุษย์ดูทั้งจุดที่สนใจและบริเวณรอบ ๆ ประกอบกัน ในการทำงานของ Convolutional Neural Network (CNN) จะมี 4 กระบวนการคือ [1]

4.1.1.1 Convolution เป็นการค้นหาคุณลักษณะของภาพออกมา การทำงานของ convolution จะทำการ filter เพื่อค้นหาองค์ประกอบของภาพ เช่น สี, เส้นขอบของวัตถุ เป็นต้น




ภาพที่ 2 ตัวอย่างขนาดภาพนำเข้า ขนาดของ filter และขนาดของภาพภาพใหม่


รูปภาพนำเข้ามีขนาด $224 \times 224 \times 3$ แต่ตัวอย่างที่ใช้ในการแสดงจะกำหนดค่าเพื่อให้ง่ายต่อการแสดงวิธีการคำนวณ โดยค่าภาพนำเข้ามีขนาดเป็น 5×5 filter มีขนาดเป็น 4×4 Padding เป็น 1 และ Stride เป็น 1 จากนั้นแทนค่าในสมการ Output feature map เพื่อหาขนาดของภาพใหม่หลังจากการทำ Convolution ได้ดังนี้

$$\text{Output Feature Map} = \frac{5 - 4 + 2(1)}{1} + 1 = 4$$

ขนาดของภาพใหม่มีขนาด 4×4 เนื่องจากกระบวนการ Convolution จะลดขนาดของภาพให้เล็กลง อาจสูญเสียบางค่าข้อมูลบนขอบภาพ เมื่อใช้ Convolution แบบต่อเนื่องหลายชั้น จึงต้องทำการเพิ่มขนาดของขอบภาพ โดยใช้ Padding เป็น 1 ทำให้ขอบของภาพทุกด้านเป็น 0 ทุกช่องเพื่อยังคงคุณลักษณะที่สำคัญของภาพไว้ [2]




ภาพที่ 3 ภาพนำเข้าที่ทำการเพิ่มขอบของภาพต้นฉบับ



ภาพที่ 4 การทำงานของ Convolution


4.1.1.2 ReLU การตรวจจับทำหน้าที่รับข้อมูลที่ได้จากการ Convolution มาแปลงให้อยู่ในรูปแบบที่ไม่เป็นเชิงเส้น (Nonlinear) โดยใช้ฟังก์ชันกระตุ้น (Activation function) เช่น Rectified Linear Unit (ReLU) ผลลัพธ์ที่ได้จากการทำ Convolution ในแต่ละตำแหน่งจะผ่านการแปลงค่าด้วย ReLU ข้อมูลจะถูกเปลี่ยนให้เป็นค่าบวกทั้งหมดหรือเป็นศูนย์ ทำให้ได้ค่าที่ไม่เป็นเชิงเส้น (Nonlinear) เพื่อความง่ายต่อการคำนวณและประเมินประสิทธิภาพ สามารถคำนวณด้วยสมการดังนี้ [3]

$$R(x) \begin{cases} 0, & \text{if } x < 0 \\ x, & \text{if } x \geq 0 \end{cases}$$




ภาพที่ 5 ตัวอย่างการทำงานของ ReLU

4.1.1.3 การพูลลิ่ง (Pooling) เป็นกระบวนการลดมิติของฟีเจอร์แมพ (Feature Map) ให้มีขนาดเล็กลง ในขณะที่ยังคงรักษารายละเอียดและข้อมูลสำคัญของภาพไว้ ซึ่งมีประโยชน์ต่อการเพิ่มความเร็วในการคำนวณและช่วยลดปัญหา overfitting ของโมเดลการพูลลิ่งสามารถแบ่งออกเป็นหลายประเภท เช่น การพูลลิ่งด้วยค่าสูงสุด (Max Pooling) และการพูลลิ่งด้วยค่าเฉลี่ย (Mean Pooling) โดยการพูลลิ่งด้วยค่าสูงสุด (Max Pooling) จะเลือกค่าที่มากที่สุดในแต่ละช่องย่อยของฟีเจอร์แมพ ซึ่งช่วยให้ข้อมูลสำคัญยังคงอยู่และจัดรายละเอียดยังคงไม่จำเป็นออกไป ตัวอย่างของการทำ Max Pooling แสดงให้เห็นถึงการเลือกค่าที่มากที่สุดจากแต่ละกลุ่มย่อยของฟีเจอร์แมพ (ดังแสดงในรูปที่ 6) เพื่อสร้างฟีเจอร์แมพที่มีขนาดเล็กลงแต่คงข้อมูลที่สำคัญ [3]




ภาพที่ 6 ตัวอย่างการการพูลลิงด้วยค่าสูงสุด (Max Pooling)

4.1.2 Dropout เป็นเทคนิคที่ใช้ในกระบวนการฝึกอบรมโมเดล Convolutional Neural Network (CNN) เพื่อลดปัญหาการ Overfitting โดยทำการสุ่มตัดโหนดบางส่วนในชั้นซ่อนออกในระหว่างการฝึก ซึ่งช่วยให้โมเดลไม่พึ่งพาคุณสมบัติใดคุณสมบัติหนึ่งมากเกินไป [3]




ภาพที่ 7 การเปรียบเทียบโครงสร้างของโครงข่ายประสาทเทียมที่ใช้เทคนิค Dropout

4.1.3 Flatten การ Flatten เป็นการแปลงข้อมูลจาก Feature Map เป็นอาร์เรย์ 1 มิติ แบบเวกเตอร์เพื่อส่งข้อมูลไปยังขั้นตอน Fully connection เป็นขั้นตอนโครงข่ายประสาทเทียมที่เป็นการรับข้อมูล Input แบบเวกเตอร์ในแนวตั้ง [4]




ภาพที่ 8 ผลลัพธ์ของการเปลี่ยนโครงสร้าง

4.1.4 Fully Connected เป็นขั้นตอนที่เชื่อมโยงระหว่าง Feature Map และ Output Layer แบบสมบูรณ์ ในขั้นตอนนี้จะรวบรวมผลการประมวลผลจากชั้นก่อนหน้า ได้แก่ Convolution, ReLU และ Max Pooling แล้วทำการแปลงข้อมูลเหล่านั้นให้อยู่ในรูปแบบเวกเตอร์ด้วยการทำ Flatten จากนั้นค่าที่ได้จากแต่ละโหนดในชั้น Fully Connected จะถูกใช้ในการจำแนกประเภทเพื่อทำนาย output ออกเป็นคลาสต่าง ๆ [3]



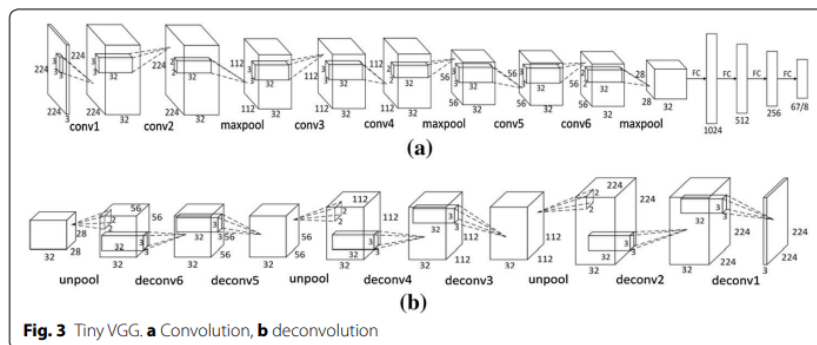
ภาพที่ 9 ภาพรวมของการ Fully connection

4.1.5 Cross Entropy Loss เป็นการเปรียบเทียบความแตกต่างที่แน่นอนระหว่างค่าผลลัพธ์ของการแจกแจงความน่าจะเป็นโดยที่ทำนาย (Prediction) และค่าจริง (Actual) [5]



ภาพที่ 10 ภาพรวมของ Cross Entropy Loss

4.1.6 VGG และ Tiny VGG



ภาพที่ 11 ภาพรวมของ Tiny VGG

VGG (Visual Geometry Group) เป็นสถาปัตยกรรมของเครือข่ายคอนโวลูชันที่ถูกนำเสนอในปี 2015 โดยกลุ่มวิจัย Visual Geometry แห่งมหาวิทยาลัยออกซฟอร์ด ซึ่งมุ่งเน้นศึกษาถึงผลกระทบของความลึกของเครือข่ายต่อความแม่นยำในการจดจำภาพขนาดใหญ่ สถาปัตยกรรมของ VGG นำเสนอวิธีการเรียนรู้คุณลักษณะที่มีความเสถียรและประสิทธิภาพสูงจากโครงสร้างข้อมูลกราฟ โดยใช้คอร์เนลคอนโวลูชันขนาดเล็กเพียง 3×3 ในทุกชั้นของเครือข่าย ซึ่ง



ต่างจากการใช้คอร์เนลขนาดใหญ่ที่เป็นวิธีดั้งเดิม การใช้คอร์เนลขนาดเล็กนี้ทำให้ VGG สามารถสร้างเครือข่ายที่มีความลึกเพิ่มขึ้นเพื่อเรียนรู้คุณลักษณะที่ซับซ้อนได้ดียิ่งขึ้น

Tiny VGG เป็นโมเดลที่มีการดัดแปลงจากสถาปัตยกรรม VGG เพื่อให้เครือข่ายมีขนาดเล็กและเบาขึ้น โดยลดจำนวนพารามิเตอร์เพื่อลดภาระในการฝึกโมเดลและป้องกันการเกิดการฝึกที่มากเกินไป (Overfitting) ซึ่งเป็นปัญหาสำคัญในงานจำแนกประเภทภาพขนาดเล็ก Tiny VGG จึงเหมาะสำหรับการจำแนกการเคลื่อนไหวหรือชนิดของวัตถุต่าง ๆ โดยเฉพาะสัตว์ป่าหรือวัตถุที่มีลักษณะเฉพาะ โครงสร้างของ Tiny VGG ยังคงมีลักษณะคล้ายกับ VGG โดยในส่วนท้ายของเครือข่ายจะมีการเชื่อมต่อ Fully Connected Layer สองชั้นหลังจากชั้นคอนโวลูชันสุดท้าย เพื่อนำคุณลักษณะที่สกัดได้ไปแมปเป็นหมวดหมู่ต่าง ๆ [6]

4.1.7 Normalization เป็นกระบวนการที่ใช้ในการปรับขนาดคุณลักษณะของข้อมูลให้มีมาตรฐาน โดยมีเป้าหมายเพื่อให้คุณลักษณะทั้งหมดอยู่ในช่วงค่าที่มีมาตราส่วนเดียวกัน กระบวนการนี้มีความสำคัญอย่างยิ่งในด้านการเรียนรู้ของเครื่องและการเรียนรู้เชิงลึก เนื่องจากสามารถช่วยปรับปรุงประสิทธิภาพของโมเดลในการเรียนรู้ โดยเฉพาะเมื่อชุดข้อมูลมีคุณลักษณะที่มีค่าหรือช่วงที่แตกต่างกันอย่างชัดเจน

- Z-Score Normalization (Standardization) กระบวนการนี้ทำให้ค่าของคุณลักษณะมีค่าเฉลี่ย (mean) เท่ากับ 0 และส่วนเบี่ยงเบนมาตรฐาน (standard deviation) เท่ากับ 1 โดยคำนวณจากสมการดังนี้ [7]

$$Z = \frac{x - \mu}{\sigma}$$

4.1.8 Confusion Matrix เป็นเครื่องมือที่ใช้ในการวัดประสิทธิภาพของโมเดลการเรียนรู้ของเครื่อง โดยเฉพาะในงานจำแนกประเภท (Classification) ซึ่งช่วยให้สามารถวิเคราะห์ความถูกต้องของการทำนายได้อย่างละเอียด โดยแสดงผลในรูปแบบของตารางที่มีค่าความถูกต้องของการทำนายในแต่ละประเภท Confusion Matrix

	Predicted Positive (1)	Predicted Negative (0)
Actual Positive (1)	True Positive	False Negative
Actual Negative (0)	False Positive	True Negative

ภาพที่ 12 ตาราง Confusion Matrix

- True Positive (TP) คือ จำนวนข้อมูลที่ทำนายได้ตรงกับสิ่งที่เกิดขึ้น กรณีทำนายว่าจริงและเหตุการณ์ที่เกิดขึ้นคือจริง
- False Negative (FN) คือ จำนวนข้อมูลที่ทำนายได้ไม่ตรงกับสิ่งที่เกิดขึ้น กรณีทำนายว่าไม่จริงแต่เหตุการณ์ที่เกิดขึ้นคือจริง
- False Positive (FP) คือ จำนวนข้อมูลที่ทำนายได้ไม่ตรงกับสิ่งที่เกิดขึ้น กรณีทำนายว่าจริงและเหตุการณ์ที่เกิดขึ้นคือไม่จริง
- True Negative (TN) คือ จำนวนข้อมูลที่ทำนายได้ตรงกับสิ่งที่เกิดขึ้น กรณีทำนายว่าไม่จริงและเหตุการณ์ที่เกิดขึ้นคือไม่จริง



โดยสามารถนำค่าต่างๆ ในตารางเหล่านี้มาคำนวณเพื่อใช้วัดประสิทธิภาพของโมเดล ได้แก่

ค่าความถูกต้อง (Accuracy) ค่าความถูกต้องแสดงถึงอัตราส่วนของการทำนายที่ถูกต้องทั้งทำนายว่าถูก และผิดต่อจำนวนตัวอย่างทั้งหมด โดยคำนวณจากสมการดังนี้

$$Accuracy = \frac{(TP + TN)}{(TP + TN + FP + FN)}$$

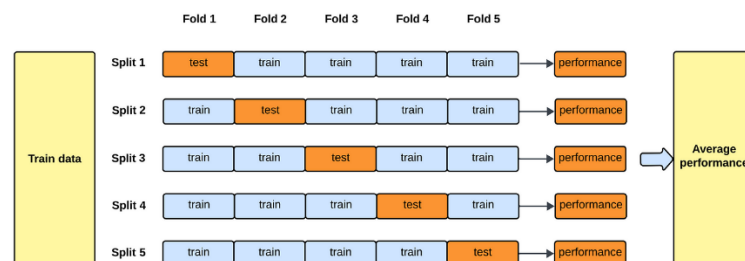
ค่าความแม่นยำ (Precision) ค่าความแม่นยำแสดงถึงความสามารถในการทำนายถูกเมื่อโมเดลทำนายว่าผลลัพธ์เป็นบวก โดยคำนวณจากสมการดังนี้

$$Precision = \frac{TP}{(TP + FP)}$$

ค่าความระลึก (Recall) ค่าความไวแสดงถึงความสามารถในการค้นพบตัวอย่างที่เป็นบวกในข้อมูลทั้งหมด ที่ควรเป็นบวกคำนวณโดยสมการดังนี้ [8]

$$Recall = \frac{TP}{(TP + FN)}$$


4.1.9 Cross Validation เป็นเทคนิคที่ใช้ในการประเมินความสามารถของโมเดลในการทำนาย โดยการแบ่งชุดข้อมูลออกเป็นหลายส่วน และทำการฝึกและทดสอบโมเดลในหลายรอบเพื่อให้ได้การประเมินที่แม่นยำยิ่งขึ้น วิธีการนี้ช่วยลดปัญหาการ overfitting โดยการใช้ข้อมูลที่แตกต่างกันในแต่ละรอบการฝึกและทดสอบ ในกระบวนการ Cross Validation จะมีการสุ่มตัวอย่างชุดข้อมูลเป็นส่วน ๆ เช่นในวิธี K-Fold Cross Validation ข้อมูลจะถูกแบ่งออกเป็น K ส่วน โดยในแต่ละรอบหนึ่งส่วนจะถูกใช้เป็นชุดทดสอบ ในขณะที่ส่วนที่เหลือจะถูกใช้เป็นชุดฝึก หลังจากทำซ้ำหลาย ๆ รอบ ผลลัพธ์จะถูกเฉลี่ยเพื่อนำเสนอการประเมินประสิทธิภาพของโมเดล



ภาพที่ 13 ภาพรวมการทำงานของ k-fold Cross Validation

การใช้ Cross Validation จึงเป็นเครื่องมือที่สำคัญในการตรวจสอบความถูกต้องและความสามารถในการทำงานของโมเดลก่อนนำไปใช้งานจริง ช่วยให้สามารถคาดการณ์ค่าความผิดพลาดได้ และเพิ่มความเชื่อมั่นในการใช้งานโมเดลในชุดข้อมูลที่ไม่เคยเห็นมาก่อน [9]

4.1.10 การเสริมข้อมูล (Data Augmentation) เป็นเทคนิคที่ได้รับความนิยมในวงการการเรียนรู้ของเครื่อง (Machine Learning) ซึ่งเกี่ยวข้องกับการสร้างข้อมูลใหม่จากข้อมูลที่มีอยู่แล้วโดยการปรับแต่งต่าง ๆ การปรับแต่งเหล่านี้อาจรวมถึงการเพิ่มสัญญาณรบกวน (noise), การพลิกรูปภาพในแนวนอน, หรือการเปลี่ยนสี เป็นต้น การทำข้อมูลเสริมเป็นวิธีที่มีประสิทธิภาพในการเพิ่มขนาดของชุดข้อมูลและปรับปรุงประสิทธิภาพของโมเดลการเรียนรู้ของเครื่อง [10]



ภาพที่ 14 การเพิ่มประสิทธิภาพสูงสุดของการเสริมข้อมูล (Data Augmentation)

4.2 งานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมของงานวิจัยนี้ได้ทำการศึกษาค้นคว้างานวิจัยที่เกี่ยวข้อง โดยมีรายละเอียดดังนี้

4.2.1 พิมพา ชีวาประกอบกิจ (2019)

ได้ทำการศึกษาวิจัยในหัวข้อ “การปรับปรุงประสิทธิภาพในการจำแนกภาพด้วยโครงข่ายประสาทแบบคอนโวลูชันโดยใช้เทคนิคการเพิ่มภาพ” ซึ่งมีวัตถุประสงค์เพื่อปรับปรุงค่าความแม่นยำของการจำแนกภาพและเปรียบเทียบค่าความแม่นยำของเทคนิคการสร้างภาพเทียมแบบต่างๆ ข้อมูลที่ใช้ในการทดลองนี้รวบรวมจาก Canada Institute for Advanced Research (CIFAR-10) ซึ่งมีทั้งหมด 60,000 ภาพ โดยแต่ละภาพมีขนาด 32x32 พิกเซล และแบ่งเป็น 10 หมวด

ในรอบแรกของการฝึกสอนคอมพิวเตอร์ให้เรียนรู้ จะใช้วิธี 10-fold Cross Validation ในการแบ่งข้อมูล โดยมี 50,000 ภาพสำหรับการฝึกสอนและ 10,000 ภาพเพื่อทดสอบ ในรอบที่ 2 จะทำการสุ่มภาพจากทุกหมวดเพื่อสร้างภาพเทียม โดยใช้เทคนิคการปรับสี การหมุน การย่อ ขยาย หรือการกลับด้านของภาพอย่างใดอย่างหนึ่ง จนได้ภาพใหม่จำนวน 10,000 ภาพ รวมกับภาพเดิม 50,000 ภาพ ทำให้มีข้อมูลทั้งหมด 60,000 ภาพ สำหรับการฝึกสอนใหม่จำนวน 300 รอบ

ผลการทดลองพบว่าการใช้เทคนิคการเพิ่มภาพด้วยการสร้างภาพเทียมช่วยให้ประสิทธิภาพในการจำแนกภาพแม่นยำสูงขึ้นจาก 84.79% เป็น 87.57% [11]

4.2.2 Kausar, A., Sharif, M., Park, J., & Shin, D. R. (2018).

ได้ทำการศึกษาวิจัยในหัวข้อ “Pure-CNN: A Framework for Fruit Images Classification” เป็นการจัดภาพหมวดหมู่ผลไม้โดยใช้ Pure Convolutional Neural Network (PCNN) ร่วมกับ Global Average Pooling (GAP) โดยพบว่าการใช้เลเยอร์ GAP สามารถแก้ปัญหาการ overfitting ได้อย่างมีประสิทธิภาพ นอกจากนี้ยังมีการประเมินความถูกต้องของการจำแนกในชุดข้อมูล Fruit-360 ซึ่งประกอบด้วยภาพผลไม้ 81 หมวด โดยผลการวิจัยพบว่าความแม่นยำของการจำแนกผลไม้ชนิดเดียวกันได้ถึง 98.88% เมื่อใช้ PCNN ร่วมกับ GAP ผลการวิจัยยังชี้ให้เห็นว่า การใช้ PCNN ร่วมกับ GAP สามารถจำแนกวัตถุและจำแนกภาพได้ในหลายระดับ ซึ่งมีประสิทธิภาพดีกว่าการใช้เพียง PCNN อย่างเดียว โดยทำให้เกิดการจำแนกภาพผิดพลาดเพียง 46 ภาพเท่านั้น และใช้เวลาในการคำนวณน้อยที่สุดที่ 20.02 วินาทีในทางตรงกันข้าม เมื่อใช้ CNN ร่วมกับ Fully Connected Layer พบว่าความถูกต้องลดลงเหลือ 97.41% โดยมีการจำแนกภาพผิดพลาด 107 ภาพ และใช้เวลาในการคำนวณมากขึ้นที่ 20.89 วินาทีจาก



การวิจัยนี้แสดงให้เห็นว่า GAP ช่วยลดปัญหาการ overfitting และเพิ่มความแม่นยำในการจำแนกภาพได้ ดีกว่าการใช้ Fully Connected Layer [12]

4.2.3 Nyoman Purnama (2024).

ได้ทำการศึกษาวิจัยในหัวข้อ "Comparison of CNN Transfer Learning in Detecting Superior Local Fruit Types in Bali" มีวัตถุประสงค์เพื่อตรวจสอบประเภทของสละในอินโดนีเซีย ผลไม้ที่ไม่เป็นที่ยอมรับเทียบกับผลไม้นำเข้า ดังนั้นจึงจำเป็นต้องมีแอปพลิเคชันเพื่อรู้ประเภทของพันธุ์ของสละนี้โดยอัตโนมัติ งานวิจัยนี้ใช้วิธีการเรียนรู้เชิงลึก (Deep Learning) ด้วยอัลกอริทึม CNN (Convolutional Neural Network) ซึ่งอัลกอริทึมนี้สามารถจำและจำแนกภาพได้อย่างแม่นยำ ภาพผลไม้ที่ใช้ในการวิจัยมีจำนวน 400 ภาพ สำหรับพันธุ์ของสละ 4 ประเภท โดยข้อมูลการฝึกของสละมีความพิเศษเพราะมีผิวและเนื้อผลไม้ที่แตกต่างกัน งานวิจัยนี้ยังได้เปรียบเทียบโมเดลการเรียนรู้เชิงถ่ายโอน (Transfer Learning) 2 แบบจากอัลกอริทึม CNN ได้แก่ MobileNetV2 และ ResNet152 จากผลการทดสอบพบว่าระดับความแม่นยำที่ดีที่สุดได้จากการใช้โมเดล ResNet152 ด้วยค่าความแม่นยำ 92% ในการระบุภาพพันธุ์ของสละบาหลี่ [13]

4.2.4 Hanna Bjorgvinsdottir and Robin Seibold (2016).

ได้ทำการศึกษาวิจัยในหัวข้อ "Face Recognition Based on Embedded Systems" โดยใช้โครงข่ายประสาทเทียมแบบคอนโวลูชัน และใช้เทคนิคการเรียนรู้เชิงถ่ายโอนข้อมูล โดยการนำตัวแบบที่มีการฝึกฝนแล้วด้วยข้อมูลขนาดใหญ่ ชื่อ VGG-16 หรือ VGG-face model (The Oxford Visual Geometry Group) ซึ่งถูกฝึกฝนด้วยชุดข้อมูลที่เป็นใบหน้าคน 2.6 ล้านรูป เพื่อจำแนกหน้าคนทั้งหมด 2,622 คน มีการใช้ Dropout เพื่อป้องกันการเกิด Overfitting แต่งานวิจัยมุ่งเน้นการใช้งานที่อุปกรณ์แบบฝังตัวทำให้เกิดข้อจำกัดทั้งด้านตัวฮาร์ดแวร์และเวลาในการฝึกฝนการที่จะฝึกฝนชุดข้อมูลทั้งหมดจึงไม่ใช่ทางเลือกที่จะใช้กับงานวิจัยดังกล่าว ดังนั้นจึงใช้เทคนิคการเรียนรู้เชิงถ่ายโอนข้อมูลโดยการโอนความรู้ที่ได้จากการฝึกฝนจากตัวแบบดังกล่าวมาใช้กับงานวิจัยโดยการฝึกฝนข้อมูลเฉพาะชั้นสุดท้ายของตัวแบบเท่านั้น ในงานวิจัยได้ใช้เทคนิคการเรียนรู้เชิงถ่ายโอนข้อมูลโดยการทดลองใช้รูปภาพในการฝึกฝนข้อมูลคลาสละ 80 ภาพจำนวน 2,904 คลาส ซึ่งให้ค่าความถูกต้องเท่ากับ 91.66 เปอร์เซ็นต์ในการจำแนกหน้าคนจำนวน 2,904 คน [14]

4.2.5 Pathak, R., and Makwana, H. (2021).

ได้ทำการศึกษาวิจัยในหัวข้อ "Classification of Fruits Using Convolutional Neural Network and Transfer Learning Models" โดยมีวัตถุประสงค์เพื่อพัฒนาและประเมินระบบการจัดหมวดหมู่ผลไม้อัตโนมัติโดยใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) ซึ่งในงานวิจัยนี้ได้ใช้ชุดข้อมูลสาธารณะจาก Kaggle ที่ชื่อว่า "Fruit Fresh and Rotten for Classification" ประกอบด้วยภาพผลไม้สดและเน่าเสียจำนวนสามชนิด ได้แก่ แอปเปิ้ล กล้วย และส้ม การวิจัยนี้ใช้โมเดล Convolutional Neural Network (CNN) ในการสกัดคุณลักษณะจากภาพผลไม้และแยกประเภทผลไม้เป็นหมวดหมู่สดและเน่าเสีย ผลลัพธ์จากการทดสอบพบว่าโมเดล CNN ที่พัฒนาขึ้นสามารถจัดหมวดหมู่ผลไม้ได้อย่างมีประสิทธิภาพด้วยความแม่นยำถึง 98.23% นอกจากนี้ งานวิจัยยังได้เปรียบเทียบประสิทธิภาพของโมเดล CNN กับวิธีการเรียนรู้เชิงถ่ายโอน (Transfer Learning) จำนวน 4 วิธี ผลการทดสอบแสดงให้เห็นว่าโมเดล CNN มีความแม่นยำและประสิทธิภาพสูงกว่าเมื่อเทียบกับโมเดลการเรียนรู้ถ่ายโอนอื่น ๆ ในการจัดหมวดหมู่ผลไม้ [15]



4.2.6 Chutima S., Kairung H. and Klaokanlaya S. (2022).

ได้ทำการศึกษาวิจัยในหัวข้อ " A Comparison of Normalization Data Transformation Efficiency Affecting with Bank Customer Credit Data Classification using Data Mining Techniques " โดยมีวัตถุประสงค์เพื่อศึกษาผลกระทบจากการแปลงข้อมูลให้เป็นมาตรฐานกับการจำแนกข้อมูลอนุมิติสินเชื่อภาพ โดยจำแนกข้อมูล 3 เทคนิค ได้แก่ เพื่อนบ้านใกล้สุด (K-NearesNeighbor) ต้นไม้ตัดสินใจ (Decision Tree) และ โครงข่ายประสาทเทียม (Neural Network) การอนุมิติสินเชื่อของลูกค้าธนาคาร โดยในงานวิจัยนี้ได้ศึกษากับข้อมูลการอนุมิติสินเชื่อของลูกค้าธนาคาร เทคนิคการแปลงข้อมูลให้เป็นมาตรฐานในรูปแบบ Min-Max, Z-score และ Mean มีผลต่อการจำแนกข้อมูลด้วยเทคนิคเพื่อนบ้านใกล้สุด (K-Nearest Neighbor) สูงสุด เนื่องจากให้ประสิทธิภาพในการจำแนกข้อมูลสูงสุด เทคนิคที่ให้ประสิทธิภาพในการจำแนกข้อมูลรองลงมา คือ เทคนิคต้นไม้ตัดสินใจ (Decision Tree) และสุดท้าย คือ เทคนิคโครงข่ายประสาทเทียม (Neural Network) ผลการทดลองพบว่า เทคนิค KNN-MinMax, KNN-Mean และ KNN-Z-score ให้ประสิทธิภาพในการจำแนกข้อมูลถึง 80.63 % ส่วนเทคนิคที่ให้ประสิทธิภาพรองลงมา คือ DT-Mean ให้ประสิทธิภาพในการจำแนกข้อมูลถึง 80.53 % รองลงมา คือ DT-MinMax และ DT-Z-score ให้ประสิทธิภาพในการจำแนกข้อมูลถึง 80.43 % ถัดมาเทคนิค NN-MinMax, NN-Mean, NN-Z-score ให้ประสิทธิภาพในการจำแนกข้อมูลถึง 77.45 % [16]

4.3 เครื่องมือและภาษาที่ใช้ในการพัฒนาระบบ

4.3.1 ภาษา Dart

เป็นภาษาการเขียนโปรแกรมหลักที่ใช้ในการพัฒนาแอปพลิเคชันที่สามารถทำงานได้บนหลายแพลตฟอร์ม เช่น Android, iOS, Web, และ Desktop โดยใช้ Flutter framework ซึ่งเป็นเครื่องมือที่ช่วยในการสร้าง User Interface (UI) ที่มีความสะดวกและรวดเร็ว ภาษา Dart มีไวยากรณ์ที่คล้ายคลึงกับภาษาการเขียนโปรแกรมอื่น ๆ เช่น C++, C#, และ Java ซึ่งช่วยให้การเรียนรู้และการทำงานกับ Dart เป็นไปได้อย่างรวดเร็ว

ภาษา Dart มีแพลตฟอร์มหลัก ๆ ที่สำคัญดังนี้ Flutter ใช้สำหรับการพัฒนาแอปพลิเคชันมือถือที่สามารถทำงานได้ทั้งบน iOS และ Android โดยการเขียนโค้ดเพียงชุดเดียว ซึ่งช่วยลดความยุ่งยากในการพัฒนาและบำรุงรักษาแอปพลิเคชันบนหลายแพลตฟอร์ม Web ใช้สำหรับการพัฒนาแอปพลิเคชันบนเว็บโดยใช้ Dart สามารถสร้างเว็บแอปพลิเคชันที่มีประสิทธิภาพสูงและตอบสนองได้ดี และ Server ใช้สำหรับการพัฒนาแอปพลิเคชันฝั่ง Server-side ซึ่งช่วยให้สามารถสร้างและจัดการเซิร์ฟเวอร์ที่มีประสิทธิภาพสูง

การใช้ Dart ร่วมกับ Flutter ช่วยให้นักพัฒนาสามารถสร้างแอปพลิเคชันที่มีคุณภาพและทำงานได้ดีในหลาย ๆ แพลตฟอร์มด้วยความสะดวกและรวดเร็ว [19]

4.3.2 ภาษา Python

เป็นภาษาการเขียนโปรแกรมที่มีชื่อเสียงและได้รับความนิยมสูงในวงการเทคโนโลยีและการพัฒนาโปรแกรม ถูกสร้างขึ้นโดย Guido van Rossum และเปิดตัวครั้งแรกในปี 1991 ภาษา Python ถูกออกแบบมาให้มีไวยากรณ์ที่เรียบง่ายและอ่านง่าย ซึ่งช่วยให้การเขียนและบำรุงรักษาโค้ดเป็นไปได้อย่างสะดวก มีลักษณะการเขียนโค้ดที่คล้ายคลึงกับภาษาอังกฤษ ทำให้การเรียนรู้และใช้งานเป็นเรื่องง่ายและ



ตรงไปตรงมา การออกแบบของ Python มุ่งเน้นไปที่การทำให้โค้ดอ่านง่ายและเขียนได้อย่างรวดเร็ว ซึ่งมีผลต่อการพัฒนาแอปพลิเคชันที่มีคุณภาพสูงและปรับปรุงโค้ดได้อย่างต่อเนื่อง

หนึ่งในเหตุผลที่ Python ได้รับความนิยมอย่างมากคือความง่ายในการเรียนรู้และใช้งาน ภาษา Python มีไวยากรณ์ที่ชัดเจนและตรงไปตรงมา ทำให้ผู้เริ่มต้นสามารถเรียนรู้ได้อย่างรวดเร็วและเข้าใจได้ง่าย ข้อกำหนดในการเขียนโค้ดมีน้อย ทำให้ผู้ใช้ไม่ต้องกังวลกับรายละเอียดเล็กน้อยที่มักพบในภาษาการเขียนโปรแกรมอื่นๆ [20]

4.3.3 Pytorch

คือ Machine Learning Framework สามารถใช้ในการสร้างโมเดล Machine Learning, Neural Network ได้ครบจบในเฟรมเวิร์คนี้ ซึ่งค่อนข้างเหมาะสมมากในการใช้งานเชิงการทดลองหรือเชิงวิจัยเพราะมีเครื่องมือให้สามารถควบคุมการทำงานของโมเดลที่หลากหลายและใช้งานง่ายอีกทั้งยังสามารถนำโมเดลไป Deploy ใช้งานจริงก็ทำได้เช่นกัน ในปัจจุบันเป็น Open Source ภายใต Linux Foundation แล้ว

Pytorch ถูกพัฒนาโดยทีม Facebook's AI Research Lab ในปี 2016 ซึ่งเป็น open-source library เปิดให้ใช้งานฟรี โดยภาษาหลักที่นิยมนำไปใช้กันคือ Python ปัจจุบัน Pytorch ได้รับความนิยมอย่างมากในการนำไปสร้างโมเดล Neural Network (Deep Learning) เนื่องจากมีลักษณะที่ค่อนข้างพร้อมต่อการใช้งานทันที จึงใช้งานได้ง่ายกว่า TensorFlow ที่เป็น Framework ประเภทเดียวกัน แต่ก็ยังสามารถปรับแต่งอะไรเพิ่มเติมได้มากกว่า Keras [21]

4.3.4 Django

Django เป็นซอฟต์แวร์ที่สามารถใช้ในการพัฒนาโปรแกรมเว็บได้อย่างรวดเร็วและมีประสิทธิภาพ การใช้งานเว็บส่วนใหญ่มีฟังก์ชันที่พบบ่อยหลายอย่าง เช่น การตรวจสอบการดึงข้อมูลจากฐานข้อมูลและการจัดการคุกกี้ นักพัฒนาต้องเข้ารหัสฟังก์ชันการทำงานที่คล้ายกันลงในทุกเว็บที่เขียน ซึ่งการใช้ Django ทำให้งานง่ายขึ้นโดยการจัดกลุ่มฟังก์ชันที่แตกต่างกันเป็นคอลเลกชัน โมดูลนำมาใช้ใหม่ขนาดใหญ่เรียกว่ากรอบแอปพลิเคชันบนเว็บ นักพัฒนาใช้กรอบเว็บ Django ในการจัดระเบียบและเขียนโค้ดอย่างมีประสิทธิภาพมากขึ้นและลดเวลาในการพัฒนาเว็บ

Django คือเฟรมเวิร์คที่ได้รับความนิยมสูงสุดของ Python และยังเป็นหนึ่งใน back-end เฟรมเวิร์คที่ได้รับความนิยมอันดับต้น ๆ ของโลก โดยสามารถดูได้จากสถิติและผลสำรวจต่าง ๆ ในแต่ละปี และในปีล่าสุดคือปี 2020 ครองอันดับ 1 back-end framework จาก stackshare.io เว็บไซต์ชื่อดังด้านโปรแกรมมิ่งอีกเว็บ รวมไปถึงผลสำรวจต่าง ๆ ไม่ว่าจะเป็น Stackoverflow Developers Survey ทาง Django ก็อยู่ในลิสต์ลำดับแรก ๆ [22]

4.3.5 Flutter

เป็น Framework ที่ใช้สร้าง UI สำหรับ Mobile Application ที่สามารถทำงานข้ามแพลตฟอร์มได้ทั้ง iOS และ Android ในเวลาเดียวกัน โดยภาษาที่ใช้ใน Flutter นั้นจะเป็นภาษา Dart ซึ่งถูกพัฒนาโดย Google และที่สำคัญคือเป็น Open Source ที่สามารถใช้งานได้แบบไม่เสียค่าใช้จ่าย

ในการรับทำโปรแกรมแล้วอยากใช้ Flutter นักพัฒนาไม่ต้องกังวลกับวิธีการใช้งาน เนื่องจาก Syntax ของภาษา Dart ที่ใช้ใน Flutter ซึ่งจะมีความคล้ายกับภาษา Java ที่เป็นที่รู้จักมาอย่างยาวนานและเป็นภาษาพื้นฐานที่นักพัฒนาส่วนใหญ่สามารถทำได้ เนื่องจาก Dart เป็นภาษาที่รองรับการเขียน โปรแกรมเชิงวัตถุ (Object-Oriented Programming) และมีแนวคิดของ Class และ Inheritance เช่นเดียวกับภาษา Java



จุดเด่นของ Flutter ระบบ Hot Reload โดยเมื่อมีการทดสอบ, การสร้าง, การ Add Features หรือการกระทำต่าง ๆ กับ UI จะต้องมีการ Reload เพื่อให้หน้า UI Update ซึ่งระบบ Hot Reload จะเข้ามาช่วยในส่วนของการ reload โดยจุดเด่นของระบบนี้คือการย่นระยะเวลาที่ใช้ในการ Reload ทำให้การพัฒนา UI ของ Application มีความรวดเร็วขึ้นอย่างมาก และยังสามารถใช้งานร่วมกับ IDE ที่กำลังเป็นที่นิยมอยู่ในปัจจุบันอย่าง VS Code และ Android Studio [23]

4.3.6 Visual Studio Code

Visual Studio Code หรือ VS Code คือ โปรแกรม Code Editor ของ Microsoft ที่ใช้สำหรับเขียนแก้ไขและตรวจสอบความผิดปกติของโค้ด คุณสมบัติของโปรแกรมมีลักษณะเบา มีประสิทธิภาพสูง มีส่วนขยาย (Extension) เพื่อเพิ่มขีดความสามารถและสามารถเขียนโค้ดได้หลากหลายภาษา สนับสนุนการเขียนโค้ดแทบทุกภาษาคอมพิวเตอร์ เช่น JavaScript, TypeScript, CSS และ HTML และยังมีส่วนขยาย (Extension) ภายในพื้นที่ขายของ VS Code Marketplace ให้เลือกใช้ได้อีกมากมาย รวมทั้งรองรับการใช้งานทั้ง Windows, MacOS และ Linux [24]

4.3.7 Android Studio

เป็น IDE Tool จาก Google ไว้พัฒนา Android สำหรับ Android Studio เป็น IDE Tools ล่าสุดจาก Google ไว้พัฒนาโปรแกรม Android โดยเฉพาะ โดยพัฒนาจากแนวคิดพื้นฐานมาจาก IntelliJ IDEA คล้าย ๆ กับการทำงานของ Eclipse และ Android ADT Plugin โดยวัตถุประสงค์ของ Android Studio คือต้องการพัฒนาเครื่องมือ IDE ที่สามารถพัฒนา App บน Android ให้มีประสิทธิภาพมากขึ้น ทั้งด้านการออกแบบ GUI ที่ช่วยให้สามารถ Preview ตัว App มุมมองที่แตกต่างกันบน Smart Phone แต่ละรุ่น สามารถแสดงผลบางอย่างได้ทันทีโดยไม่ต้องทำการรัน App บน Emulator รวมทั้งยังแก้ไขปรับปรุงในเรื่องของความเร็วของ Emulator ที่ยังเจอปัญหาค้างอยู่ในปัจจุบัน [25]

4.3.8 PostgreSQL

PostgreSQL เป็นระบบจัดการฐานข้อมูลเชิงสัมพันธ์แบบโอเพ่นซอร์สระดับองค์กรที่มีความสามารถสูง รองรับการจัดการข้อมูลแบบเชิงสัมพันธ์ด้วย SQL และข้อมูลแบบไม่เชิงสัมพันธ์ผ่าน JSON ด้วยชุมชนผู้พัฒนาที่แข็งแกร่งและการสนับสนุนที่ดี PostgreSQL จึงเป็นหนึ่งในฐานข้อมูลที่มีความน่าเชื่อถือสูง โดยเน้นด้านความปลอดภัยและความถูกต้องของข้อมูล

PostgreSQL ได้รับความนิยมอย่างกว้างขวางในกลุ่มนักพัฒนาโทรศัพท์มือถือและเว็บแอปพลิเคชัน โดยมักถูกเลือกเป็นฐานข้อมูลเริ่มต้น เนื่องจากมีคุณสมบัติที่หลากหลาย รองรับการพัฒนาแอปพลิเคชันที่ต้องการความสมบูรณ์ของข้อมูล อีกทั้งยังช่วยให้ผู้ดูแลระบบสามารถสร้างสภาพแวดล้อมที่ทนต่อความผิดพลาดได้ PostgreSQL ยังรองรับการทำงานข้ามแพลตฟอร์มและสามารถใช้งานร่วมกับภาษาการเขียนโปรแกรมยอดนิยมต่างๆ ทำให้เป็นตัวเลือกที่เหมาะสมสำหรับการพัฒนาโซลูชันเชิงพื้นที่และการวิเคราะห์ [26]

4.3.9 Google Colab

Google Colab (ย่อมาจาก Colaboratory) เป็นบริการคลาวด์ฟรีที่ให้ผู้ใช้งานสามารถเขียนและรันโค้ด Python ผ่านเว็บเบราว์เซอร์ได้ โดยไม่ต้องติดตั้งซอฟต์แวร์ใดๆ บนเครื่องคอมพิวเตอร์ของตนเอง มันใช้รูปแบบของ Jupyter Notebook ซึ่งเป็นสภาพแวดล้อมการเขียนโปรแกรมแบบโต้ตอบที่ได้รับความนิยมในชุมชนวิทยาศาสตร์ข้อมูลและการเรียนรู้ของเครื่อง



คุณสมบัติเด่นของ Google Colab คือ ผู้ใช้สามารถเข้าถึง GPU และ TPU ได้ฟรี ซึ่งเป็นประโยชน์สำหรับการฝึกโมเดล Machine Learning และ Deep Learning ที่ต้องการพลังการประมวลผลสูง และสามารถทำงานร่วมกับผู้อื่นได้อย่างง่ายดายเหมือนกับการใช้ Google Docs โดยมีไลบรารียอดนิยมสำหรับ Data Science และ Machine Learning ติดตั้งไว้ เช่น TensorFlow, PyTorch, Scikit-learn เป็นต้น [27]

4.3.10 Figma

เป็นเครื่องมือออกแบบอินเทอร์เฟซแบบทำงานร่วมกัน (the collaborative interface design tool) ซึ่งความสามารถในการทำงานร่วมกัน (collaborative) กลายเป็นจุดเด่นที่ทำให้ Figma ได้รับความนิยมในแวดวงนักออกแบบ UX/UI เพราะในโลกของการทำงานจริงเหล่านักออกแบบหลายครั้งต้องทำงานร่วมกับนักออกแบบคนอื่นๆ ไปจนถึงผู้ที่เกี่ยวข้อง (Stakeholders) อาทิ Product Manager, Developer, Marketing เป็นต้น

นักออกแบบจึงไม่ได้ใช้ Figma สำหรับแค่การจัดวางเลย์เอาต์อินเทอร์เฟซ แต่ยังใช้สำหรับการสร้างแบบจำลอง (Prototype) และฟรีเซชันงานเพื่อให้เกิดความเข้าใจที่ตรงกัน และยังสามารถแชร์ Design System เพื่อให้สามารถหยิบยืมงานกันได้ และทำให้งานออกแบบในภาพรวมมีความสอดคล้องกัน ด้วยความสามารถที่หลากหลายและครบครัน ทำให้ Figma กลายเป็นเครื่องมือที่ได้พิสูจน์ตัวเองแล้วว่าเป็นเครื่องมือที่ทำมาได้อย่างตอบโจทย์การทำงานทั้งกระบวนการดิจิทัลอย่างแท้จริง ทั้งนักออกแบบ และทีมสามารถใช้ประโยชน์จากฟังก์ชันการทำงานร่วมกัน อีกทั้งยังใช้ทำงานร่วมกับโปรแกรมอื่นๆ ได้อย่างสะดวก [28]

4.3.11 Postman

เป็นเครื่องมือทดสอบที่ช่วยให้นักพัฒนาแอปฯ สามารถสร้าง ทดสอบ และแก้ไข API ได้ ซึ่งอินเทอร์เฟซผู้ใช้ของเครื่องมือทดสอบ API นี้ช่วยให้ developer และ QA สามารถส่ง HTTP request และติดตามการตอบสนองได้อย่างง่ายดาย ด้วยเครื่องมือทดสอบ Postman คุณสามารถเข้าถึงชุดเครื่องมือที่ครอบคลุมซึ่งช่วยเร่งวงจรการใช้งาน API ได้อย่างครบวงจร ตั้งแต่การออกแบบ การทดสอบ ไปจนถึงเอกสารประกอบและการทำต้นแบบ

Postman เติบโตขึ้นมาในฐานะเครื่องมือยอดนิยมด้วยเหตุผลหลายประการ ซึ่งรวมถึงการเข้าถึงหลังจากติดตั้ง Postman บนอุปกรณ์แล้ว คุณสามารถเข้าถึงได้จากทุกที่โดยลงชื่อเข้าใช้บัญชีที่เชื่อมโยงกับอุปกรณ์นั้นการทดสอบการพัฒนา ทุกคำขอ API ควรจัดให้มีจุดตรวจสอบสถานะการตอบสนอง HTTP ที่ประสบความสำเร็จ และการสร้าง environment ซึ่ง environment ที่หลากหลายช่วยลดความซ้ำซ้อนในการทดสอบเนื่องจาก collection เดียวกันอาจใช้ในการตั้งค่าที่แตกต่างกัน [29]



5. ระเบียบวิธีวิจัย (Research Methodology)

5.1 การออกแบบระบบ แอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์ ได้ออกแบบโครงสร้างของระบบเพื่อให้่ายต่อการใช้งานและการจัดการแก้ไข ดังต่อไปนี้

5.1.1 โครงสร้างโมเดล

ตารางที่ 1 ขั้นตอนการทำงานของ Tiny VGG

Layer	Layer Type	Output Size	Kernel Size	Stride	Padding	Additional Info
Input		224 x 224 x 3				
Block 1						
Conv2d	Convolution	224 x 224 x 64	3x3	1	1	ReLU
MaxPool2d	Max Pooling	112 x 112 x 64	2x2	2	0	
Block 2						
Conv2d	Convolution	112 x 112 x 128	3x3	1	1	ReLU
MaxPool2d	Max Pooling	56 x 56 x 128	2x2	2	0	
Block 3						
Conv2d	Convolution	56 x 56 x 256	3x3	1	1	ReLU
MaxPool2d	Max Pooling	28 x 28 x 256	2x2	2	0	
Block 4						
Conv2d	Convolution	28 x 28 x 512	3x3	1	1	ReLU
MaxPool2d	Max Pooling	14 x 14 x 512	2x2	2	0	
Block 5						
Conv2d	Convolution	14 x 14 x 512	3x3	1	1	ReLU
MaxPool2d	Max Pooling	7 x 7 x 512	2x2	2	0	
Classifier						
Flatten		1 x 1 x 4096				
Fully Connected	Fully Connected	1 x 1 x 4096				
Fully Connected	Fully Connected	1 x 1 x 4096				
Fully Connected	Fully Connected	1 x 1 x 1000				

ตารางที่ 2 ขั้นตอนการทำงานของ CNN

Layer	Layer Type	Output Size	Kernel Size	Stride	Padding	Additional info
Input		224 x 224 x 3				
Block 1						
	Conv2d	116 x 116 x 40	4	2	5	ReLU
	Conv2d	60 x 60 x 40	4	2	3	ReLU
	MaxPool2d	30 x 30 x 40	2	2	0	
Block 2						
	Conv2d	30 x 30 x 40	3	1	1	ReLU
	Conv2d	30 x 30 x 40	3	1	1	ReLU
	MaxPool2d	15 x 15 x 40	2	2	0	
Block 3						
	Conv2d	15 x 15 x 40	3	1	1	ReLU
	MaxPool2d	5 x 5 x 40	3	3	0	
Classifier						
	Flatten	1000 (40 x 5 x 5)				
	Fully connected layer	9 (output classes)	-	-	-	



จากตารางข้างต้น เป็นการออกแบบโมเดล Convolutional Neural Network (CNN) โดยโมเดลนี้ได้รับการพัฒนาขึ้นโดยใช้แนวคิดที่คล้ายคลึงกับสถาปัตยกรรม VGG และ Tiny VGG โดยมีโครงสร้างคล้ายกับ VGG ที่ผ่านการปรับแต่งให้เล็กลงเช่นเดียวกับ Tiny VGG ซึ่งมีประสิทธิภาพสูงในการจำแนกประเภทภาพ โดยเฉพาะการจำแนกผักและผลไม้ โมเดลนี้มีการประมวลผลภาพที่มี 3 ช่องสัญญาณ (RGB) และประกอบไปด้วยหลาย Layers ได้แก่ Convolutional Layers, Pooling Layers, Dropout Layer, และ Fully Connected Layer

การออกแบบโมเดลนี้ได้มีการปรับแต่งเพื่อให้เหมาะสมกับชุดข้อมูลที่ใช้ในงาน โดยการปรับขนาดของ Feature Map, จำนวน Filters

5.1.2 โครงสร้างแอปพลิเคชัน (System Architecture Diagram)


5.1.2.1 Flutter (Frontend Library) เป็นเฟรมเวิร์กที่ใช้สำหรับการพัฒนาส่วน Frontend โดยมีการทำงาน ดังนี้

1. สร้าง UI ที่ตอบสนองสำหรับผู้ใช้งานบนทั้งแพลตฟอร์ม Android และ iOS
2. ใช้ Widgets ในการออกแบบหน้าจอและจัดการการแสดงผลของข้อมูล
3. ผสานการทำงานกับ HTTP หรือ Dio สำหรับการส่งและรับข้อมูลจาก API
4. ใช้ Flutter Router หรือ Navigator ในการจัดการการเปลี่ยนหน้าจอ (Navigation)

5.1.2.2 Django (Backend Framework) เป็น Backend Framework ที่ใช้ภาษา Python สำหรับการพัฒนาส่วน Backend โดยมีหน้าที่ดังนี้

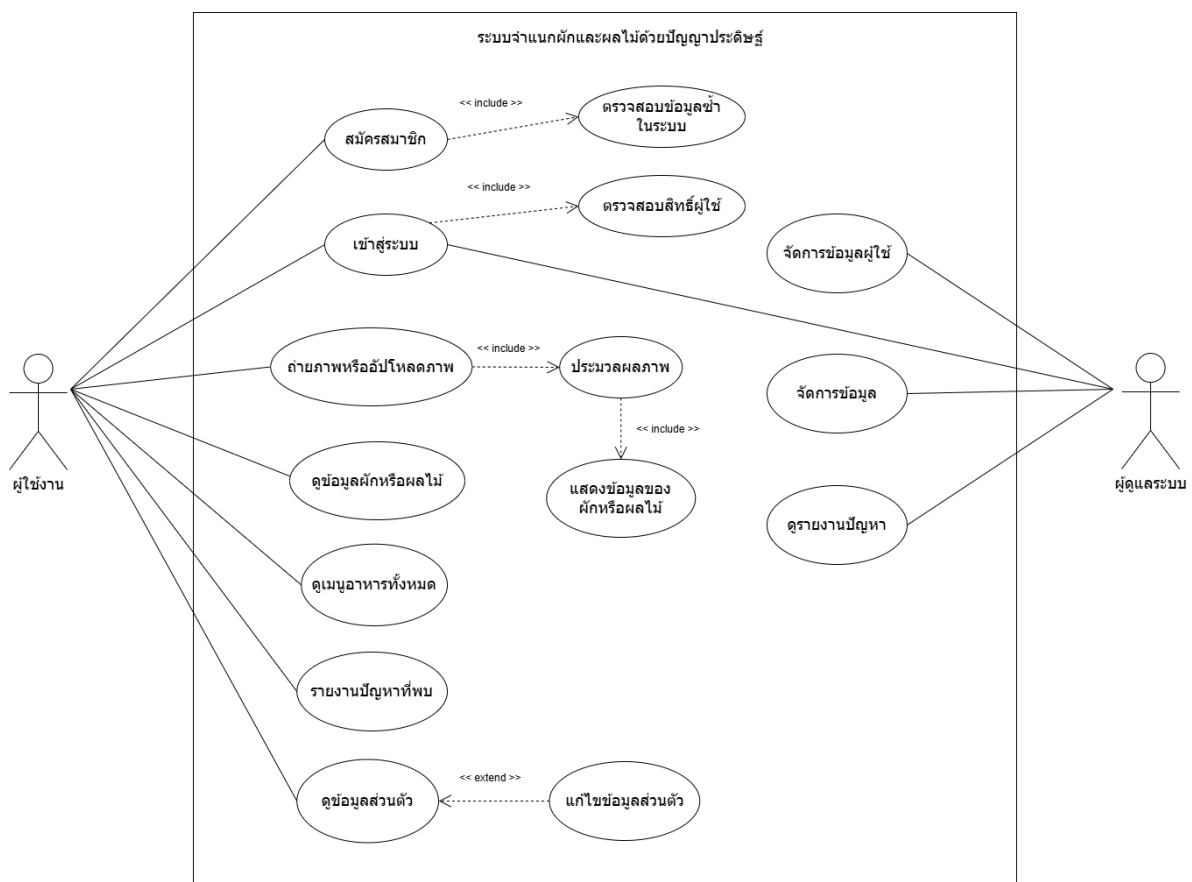
1. สร้าง RESTful API ด้วย Django REST framework สำหรับเชื่อมต่อกับส่วน Frontend
2. จัดการฐานข้อมูลผ่าน ORM (Object-Relational Mapping) เพื่อการเพิ่ม ลบ หรือ ปรับปรุงข้อมูล
3. ใช้ JSON Web Tokens (JWT) เพื่อจัดการการยืนยันตัวตน (Authentication) และการอนุญาต (Authorization)
4. ใช้ Serializers ในการแปลงข้อมูลระหว่างแบบจำลอง (Model) และ JSON
5. การประมวลผลข้อมูลจากโมเดล Machine Learning จะทำผ่าน API ใน Django เพื่อส่งภาพไปยังโมเดลและรับผลลัพธ์กลับมาในรูปแบบ JSON สำหรับแสดงผลใน frontend

5.1.2.3 การวางผังหน้าแอปพลิเคชัน จะมีการแบ่งโครงสร้างออกเป็น 3 ส่วน คือ



1. Header Component คือ ส่วนของหัวข้อหลักของแอปพลิเคชันที่อยู่ด้านบนของหน้าจอ
2. Content Section คือ ส่วนตรงกลางหน้าจอที่แสดงข้อมูลหลักของแอปพลิเคชัน
3. Menu Component คือ ส่วนเมนูที่อยู่ด้านล่างของหน้าจอสำหรับการนำทางไปยังหน้าต่างๆ

5.1.3 Use Case Diagram



ภาพที่ 15 Use Case Diagram ระบบจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์



คำอธิบาย Use Case ระบบจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์ มีดังนี้

1. Use Case การสมัครสมาชิกและการตรวจสอบข้อมูลซ้ำในระบบ

ตารางที่ 3 คำอธิบายขั้นตอนการสมัครสมาชิก

Use Case ID	1
Use Case Name	การสมัครสมาชิก
Actor	ผู้ใช้งานระบบ
Purpose	เพื่อให้ผู้ใช้งานสามารถลงทะเบียนบัญชีผู้ใช้ในระบบเพื่อเข้าถึงฟังก์ชันการทำงานของแอปพลิเคชัน
Level	Primary Use Case
Preconditions	ผู้ใช้งานยังไม่มีบัญชีในระบบ
Post conditions	<ul style="list-style-type: none">- ระบบบันทึกบัญชีผู้ใช้ใหม่ในฐานข้อมูล และผู้ใช้งานสามารถเข้าสู่ระบบได้- ผู้ใช้งานได้รับการยืนยันตัวตนเรียบร้อยแล้ว
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานเปิดหน้าลงทะเบียนและกรอกข้อมูลที่จำเป็น เช่น อีเมลและรหัสผ่าน2. ผู้ใช้งานกดปุ่ม "สมัครสมาชิก"3. ระบบตรวจสอบข้อมูลที่กรอกว่าถูกต้อง เช่น อีเมลมีรูปแบบที่ถูกต้องและรหัสผ่านตรงตามเงื่อนไขความปลอดภัย4. หากข้อมูลถูกต้อง ระบบจะสร้างบัญชีผู้ใช้ใหม่และแจ้งเตือนว่าการสมัครเสร็จสมบูรณ์ ผู้ใช้งานสามารถเข้าสู่ระบบได้
Alternate Condition	<ol style="list-style-type: none">1. หากผู้ใช้งานกรอกข้อมูลไม่ถูกต้อง ระบบจะแสดงข้อผิดพลาดและให้ผู้ใช้งานแก้ไขข้อมูลใหม่

ตารางที่ 4 คำอธิบายขั้นตอนการตรวจสอบข้อมูลซ้ำในระบบ

Use Case ID	1.1
Use Case Name	ตรวจสอบข้อมูลซ้ำในระบบ
Actor	ระบบ
Purpose	เพื่อทำการตรวจสอบข้อมูลการสมัครสมาชิกในระบบว่าซ้ำกันกับในระบบหรือไม่
Level	Include
Preconditions	หลังกดยืนยันการกรอกข้อมูลการสมัคร
Post conditions	ระบบได้ทำการตรวจสอบข้อมูลในระบบ
Main Flows	<ol style="list-style-type: none">1. ระบบตรวจสอบข้อมูลที่กรอกว่าเป็นข้อมูลซ้ำหรือไม่2. หากข้อมูลไม่ซ้ำ ผู้ใช้สามารถทำการสมัครสมาชิกด้วยอีเมลนี้ได้3. หากข้อมูลซ้ำ จะให้ผู้ใช้ทำการสมัครด้วยอีเมลอื่นใหม่อีกครั้ง
Alternate Condition	<ol style="list-style-type: none">1. มีข้อมูลซ้ำอยู่แล้วในระบบ



2. Use Case การเข้าสู่ระบบและตรวจสอบสิทธิ์ผู้ใช้

ตารางที่ 5 คำอธิบายขั้นตอนการเข้าสู่ระบบ

Use Case ID	2
Use Case Name	เข้าสู่ระบบ
Actor	ผู้ใช้งานระบบ, ผู้ดูแลระบบ
Purpose	เพื่อให้ผู้ใช้งานสามารถเข้าสู่ระบบและเข้าถึงฟังก์ชันการทำงานที่เกี่ยวข้องตามสิทธิ์ของตน
Level	Primary Use Case
Preconditions	ได้ทำการลงทะเบียนและได้รับอีเมลยืนยันจากระบบแล้ว
Post conditions	สามารถเข้าสู่ระบบได้
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานกรอกข้อมูล เช่น อีเมลและรหัสผ่านในหน้าเข้าสู่ระบบ2. ผู้ใช้งานกดปุ่ม "เข้าสู่ระบบ"3. ระบบตรวจสอบความถูกต้องของข้อมูลที่กรอก4. หากข้อมูลถูกต้อง ระบบตรวจสอบสิทธิ์การเข้าถึงของผู้ใช้งาน5. หากผู้ใช้งานเป็นผู้ดูแลระบบ ระบบนำไปยังหน้าจัดการข้อมูลในระบบ6. หากผู้ใช้งานเป็นผู้ใช้ทั่วไป ระบบนำไปยังหน้าแรกของแอปพลิเคชันเพื่อเข้าถึงฟังก์ชันปกติ
Alternate Condition	<ol style="list-style-type: none">1. หากผู้ใช้งานกรอกข้อมูลไม่ถูกต้อง ระบบจะแสดงข้อผิดพลาดและให้ผู้ใช้งานลองใหม่

ตารางที่ 6 คำอธิบายขั้นตอนการตรวจสอบสิทธิ์ผู้ใช้

Use Case ID	2.1
Use Case Name	การตรวจสอบสิทธิ์ผู้ใช้
Actor	ระบบ
Purpose	เพื่อทำการตรวจสอบสิทธิ์ก่อนเข้าสู่ระบบ
Level	Include
Preconditions	กรอกข้อมูลเข้าสู่ระบบ ได้แก่ อีเมลและรหัสผ่าน
Post conditions	แสดงสิทธิ์การเข้าใช้งานจากข้อมูลที่กรอก
Main Flows	<ol style="list-style-type: none">1. ระบบตรวจสอบว่าข้อมูลมีอยู่ในระบบหรือไม่2. หากไม่มีข้อมูลในระบบ หรืออีเมลกับรหัสผ่านไม่ตรงกัน ให้ทำการล็อกอินใหม่3. หากมีข้อมูลในระบบ ให้ระบบนำผู้ใช้งานไปยังหน้าหลัก
Alternate Condition	<ol style="list-style-type: none">1. ไม่มีข้อมูลการสมัครในระบบ2. หากอีเมลและรหัสผ่านไม่ตรงกัน ระบบจะแจ้งเตือนว่าข้อมูลไม่ถูกต้องและให้ผู้ใช้งานกรอกใหม่



3. Use Case การถ่ายภาพหรืออัปโหลดภาพ ประมวลผลภาพ และแสดงข้อมูลของผักและผลไม้

ตารางที่ 7 คำอธิบายขั้นตอนการถ่ายภาพหรืออัปโหลดภาพ

Use Case ID	3
Use Case Name	ถ่ายภาพหรืออัปโหลดภาพ
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานถ่ายภาพหรืออัปโหลดภาพ
Level	
Preconditions	ผู้ใช้งานต้องเข้าสู่ระบบแล้ว
Post conditions	ภาพถูกบันทึกและพร้อมสำหรับการประมวลผล
Main Flows	1. ผู้ใช้งานเลือกถ่ายภาพหรืออัปโหลดภาพ 2. ระบบบันทึกภาพเพื่อประมวลผล
Alternate Condition	-

ตารางที่ 8 คำอธิบายขั้นตอนการประมวลผลภาพ

Use Case ID	3.1
Use Case Name	ประมวลผลภาพ
Actor	ระบบ
Purpose	เพื่อทำการประมวลผลภาพ
Level	Include
Preconditions	มีภาพที่ถูกอัปโหลดหรือถ่ายมาแล้ว
Post conditions	แสดงข้อมูลที่ประมวลผลแล้วของผลไม้หรือผัก
Main Flows	1. ประมวลผลภาพว่ารูปภาพที่ผู้ใช้ถ่ายหรืออัปโหลดนั้นตรงกับข้อมูลที่มีอยู่ในระบบหรือไม่ 2. ถ้าไม่มีให้แสดงผลลัพธ์ว่าไม่มีผลลัพธ์ ให้ทำการแสกนใหม่อีกครั้ง 3. ถ้ามีข้อมูลในระบบให้แสดงผลลัพธ์เป็นชื่อชนิดของผักหรือผลไม้ที่ประมวลผลได้
Alternate Condition	1. หากไม่สามารถประมวลผลภาพได้ ระบบจะแจ้งเตือนข้อผิดพลาด เช่น ไม่มีข้อมูลผักหรือผลไม้ชนิดนี้



ตารางที่ 9 คำอธิบายขั้นตอนการแสดงผลของผักและผลไม้

Use Case ID	3.2
Use Case Name	แสดงผลข้อมูลของผักและผลไม้
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานสามารถดูข้อมูลเกี่ยวกับผักและผลไม้ได้
Level	include
Preconditions	ระบบต้องประมวลผลภาพสำเร็จ
Post conditions	ข้อมูลผักและผลไม้ถูกแสดงให้ผู้ใช้งานดู
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานเลือกดูข้อมูลของผักและผลไม้2. ระบบดึงข้อมูลของผักและผลไม้ที่เกี่ยวข้อง3. ระบบแสดงผลข้อมูลของผักหรือผลไม้ที่ประมวลผลได้ โดยมีข้อมูลดังนี้<ol style="list-style-type: none">3.1 ข้อมูลการเลือกซื้อผักและผลไม้3.2 ข้อมูลคุณสมบัติของผักและผลไม้3.3 ข้อมูลการจัดเก็บผักและผลไม้
Alternate Condition	<ol style="list-style-type: none">1. หากไม่มีข้อมูลในระบบ ระบบแจ้งเตือนข้อผิดพลาด

4. Use Case ดูข้อมูลเมนูจากผักและผลไม้

ตารางที่ 10 คำอธิบายขั้นตอนการดูข้อมูลเมนูอาหารจากผักและผลไม้

Use Case ID	4
Use Case Name	ดูข้อมูลเมนูอาหารจากผักและผลไม้
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานสามารถดูข้อมูลเกี่ยวกับเมนูอาหารที่ใช้ผักและผลไม้เป็นส่วนประกอบ
Level	Primary Use Case
Preconditions	ผู้ใช้งานต้องเข้าสู่ระบบ
Post conditions	ระบบแสดงผลข้อมูลเมนูอาหารจากผักและผลไม้ที่ผู้ใช้งานเลือกดู
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานเลือกตัวเลือก "เมนูอาหาร" จากเมนูหลัก2. ระบบแสดงรายการเมนูทั้งหมดที่ใช้ผักและผลไม้3. ผู้ใช้งานสามารถเลือกเมนูที่ต้องการดูรายละเอียด4. ผู้ใช้งานส่งข้อมูลการรายงาน5. ระบบจะแสดงผลรายละเอียดของเมนู เช่น ชื่อเมนู, คำอธิบาย และลิงก์สำหรับไปหน้าเว็บไซต์เพื่อดูขั้นตอนการทำ
Alternate Condition	-



5. Use Case การรายงานปัญหา

ตารางที่ 11 คำอธิบายขั้นตอนการรายงานปัญหา

Use Case ID	5
Use Case Name	รายงานปัญหา
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานสามารถรายงานข้อบกพร่องหรือปัญหาที่พบในการใช้งานระบบ
Level	Primary Use Case
Preconditions	ผู้ใช้งานต้องมีบัญชีและล็อกอินเข้าสู่ระบบก่อนรายงานปัญหา
Post conditions	รายงานปัญหาถูกบันทึกในระบบและผู้ใช้งานได้รับข้อความยืนยันการส่งรายงาน
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานเลือกฟังก์ชันการรายงานปัญหา2. ระบบแสดงแบบฟอร์มให้กรอกรายละเอียดเกี่ยวกับปัญหา3. ผู้ใช้งานกรอกข้อมูลเกี่ยวกับปัญหาที่พบ4. ผู้ใช้งานส่งข้อมูลการรายงาน5. ระบบบันทึกข้อมูลรายงานและแสดงข้อความยืนยันการส่ง
Alternate Condition	<ol style="list-style-type: none">1. ผู้ใช้งานไม่กรอกข้อมูลในฟิลด์ที่จำเป็น2. ระบบแจ้งเตือนว่าต้องกรอกข้อมูลให้ครบถ้วนก่อนส่งรายงาน

6. Use Case ดูข้อมูลส่วนตัว และแก้ไขโปรไฟล์ส่วนตัว

ตารางที่ 12 คำอธิบายขั้นตอนดูข้อมูลส่วนตัว

Use Case ID	6
Use Case Name	ดูข้อมูลส่วนตัว
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานสามารถเข้าถึงและดูข้อมูลส่วนตัวของตนเองได้
Level	Primary Use Case
Preconditions	ผู้ใช้งานต้องเข้าสู่ระบบและอยู่ในหน้าโปรไฟล์ส่วนตัว
Post conditions	ระบบจะแสดงข้อมูลส่วนตัวของผู้ใช้งาน
Main Flows	<ol style="list-style-type: none">1. ผู้ใช้งานดูข้อมูลส่วนตัวจากเมนูโปรไฟล์2. ระบบดึงข้อมูลโปรไฟล์ของผู้ใช้งานจากฐานข้อมูล3. ระบบแสดงข้อมูลส่วนตัวทั้งหมดให้ผู้ใช้งานดู เช่น ชื่อ และรูปโปรไฟล์4. ผู้ใช้งานสามารถเลือกที่จะกลับไปยังหน้าหลักหรือทำการแก้ไขข้อมูลได้
Alternate Condition	-



ตารางที่ 13 คำอธิบายขั้นตอนการแก้ไขโปรไฟล์ส่วนตัว

Use Case ID	6.1
Use Case Name	แก้ไขโปรไฟล์ส่วนตัว
Actor	ผู้ใช้งาน
Purpose	เพื่อให้ผู้ใช้งานสามารถอัปเดตข้อมูลส่วนตัว
Level	extend
Preconditions	ผู้ใช้งานต้องเข้าสู่ระบบและอยู่ในหน้าโปรไฟล์ส่วนตัว
Post conditions	ระบบจะบันทึกการเปลี่ยนแปลงและแสดงข้อมูลโปรไฟล์ที่อัปเดต
Main Flows	1. ผู้ใช้งานเลือกตัวเลือก "แก้ไขโปรไฟล์" จากหน้าโปรไฟล์ส่วนตัว 2. ระบบแสดงฟอร์มให้ผู้ใช้งานกรอกข้อมูลที่ต้องการแก้ไข 3. ผู้ใช้งานกรอกข้อมูลใหม่ เช่น ชื่อ และรูปโปรไฟล์ 4. ผู้ใช้งานคลิกปุ่ม "บันทึก" 5. ระบบทำการบันทึกข้อมูลและแสดงข้อความยืนยันการบันทึก
Alternate Condition	1. ถ้าผู้ใช้งานไม่กรอกข้อมูลที่จำเป็น ระบบจะแจ้งเตือนให้กรอกข้อมูล

7. Use Case จัดการผู้ใช้งาน

ตารางที่ 14 คำอธิบายขั้นตอนการจัดการผู้ใช้งาน

Use Case ID	7
Use Case Name	จัดการผู้ใช้งาน
Actor	ผู้ดูแลระบบ
Purpose	เพื่อให้ผู้ดูแลระบบสามารถเพิ่ม, แก้ไข, หรือลบข้อมูลผู้ใช้งานในระบบได้
Level	Primary Use Case
Preconditions	ผู้ดูแลระบบต้องเข้าสู่ระบบและมีสิทธิ์ในการจัดการผู้ใช้งาน
Post conditions	ระบบจะบันทึกการเปลี่ยนแปลงข้อมูลผู้ใช้งานและแสดงผลลัพธ์ที่ถูกต้อง
Main Flows	1. ผู้ดูแลระบบเลือกตัวเลือก "จัดการผู้ใช้งาน" จากเมนูการจัดการ 2. ระบบแสดงรายการผู้ใช้งานทั้งหมด 3. ผู้ดูแลระบบสามารถเลือกผู้ใช้งานที่ต้องการจัดการ 4. ผู้ดูแลระบบสามารถเพิ่ม, แก้ไข, หรือลบข้อมูลผู้ใช้งาน 5. ระบบจะบันทึกการเปลี่ยนแปลงและแสดงข้อความยืนยันการดำเนินการ
Alternate Condition	-



8. Use Case จัดการข้อมูล

ตารางที่ 15 คำอธิบายขั้นตอนการจัดการข้อมูล

Use Case ID	8
Use Case Name	จัดการข้อมูล
Actor	ผู้ดูแลระบบ
Purpose	เพื่อให้ผู้ดูแลระบบสามารถเพิ่ม, แก้ไข, หรือลบข้อมูลที่เกี่ยวข้องกับผักและผลไม้ รวมถึงเมนูอาหารในระบบได้
Level	Primary Use Case
Preconditions	ผู้ดูแลระบบต้องเข้าสู่ระบบและมีสิทธิ์ในการจัดการข้อมูล
Post conditions	ระบบจะบันทึกการเปลี่ยนแปลงข้อมูลผู้ใช้งานและแสดงผลลัพธ์ที่ถูกต้อง
Main Flows	<ol style="list-style-type: none">1. ผู้ดูแลระบบเลือกตัวเลือก "จัดการข้อมูล" จากเมนูการจัดการระบบแสดงรายการผู้ใช้งานทั้งหมด2. ระบบแสดงรายการข้อมูลผักและผลไม้ทั้งหมด3. ผู้ดูแลระบบสามารถเลือกข้อมูลที่ต้องการจัดการ (เพิ่ม, แก้ไข, หรือลบ)4. ผู้ดูแลระบบกรอกข้อมูลใหม่หรือตรวจสอบข้อมูลที่มีอยู่5. ระบบจะบันทึกการเปลี่ยนแปลงและแสดงข้อความยืนยันการดำเนินการ
Alternate Condition	<ol style="list-style-type: none">1. ถ้าผู้ดูแลระบบไม่กรอกข้อมูลที่จำเป็นในฟอร์มเพิ่มหรือแก้ไข ระบบจะแจ้งเตือนให้กรอกข้อมูล

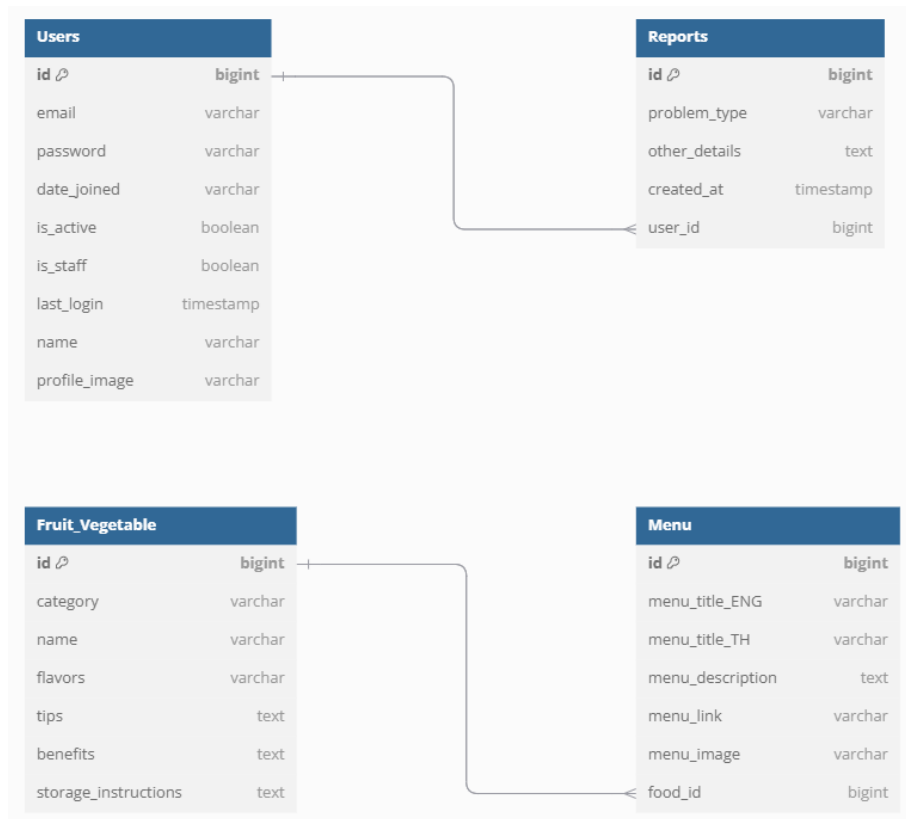
9. Use Case ปัญหาที่ผู้ใช้รายงาน

ตารางที่ 16 คำอธิบายขั้นตอนการปัญหาที่ผู้ใช้รายงาน

Use Case ID	9
Use Case Name	ปัญหาที่ผู้ใช้รายงาน
Actor	ผู้ดูแลระบบ
Purpose	เพื่อให้ผู้ดูแลระบบสามารถดูและจัดการปัญหาที่ผู้ใช้ได้ทำการรายงานไว้
Level	Primary Use Case
Preconditions	ผู้ดูแลระบบต้องเข้าสู่ระบบและมีสิทธิ์ในการดูปัญหาที่ผู้ใช้รายงาน
Post conditions	ระบบจะแสดงรายการปัญหาที่ผู้ใช้รายงานและสถานะของปัญหานั้น ๆ
Main Flows	<ol style="list-style-type: none">1. ผู้ดูแลระบบเลือกตัวเลือก "ปัญหาที่รายงาน" จากเมนูการจัดการ2. ระบบแสดงรายการปัญหาที่ผู้ใช้งานได้ทำการรายงาน3. ผู้ดูแลระบบสามารถเลือกดูรายละเอียดของปัญหาที่รายงาน4. ผู้ดูแลระบบสามารถทำการตอบกลับหรือดำเนินการแก้ไขปัญหาที่ผู้ใช้งานได้รายงาน
Alternate Condition	<ol style="list-style-type: none">1. ถ้าหากไม่มีการรายงานปัญหา ระบบจะแจ้งเตือนว่าปัจจุบันไม่มีปัญหาที่ผู้ใช้รายงาน



5.1.4 Entity-Relationship Diagram: ERD



ภาพที่ 16 Entity-Relationship Diagram แอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์

5.1.5 พจนานุกรมของแหล่งจัดเก็บข้อมูล (Data Dictionary)

ตารางที่ 17 ตารางพจนานุกรมของแหล่งจัดเก็บข้อมูลเพิ่มข้อมูลของผู้ใช้

accepts: เพิ่มข้อมูลของผู้ใช้				
Field Name	Data Type	Key type	Permissible value	Description
id	bigint(20)	PK		รหัสผู้ใช้งาน (Primary Key)
email	varchar(255)	Unique		อีเมลที่ใช้เข้าสู่ระบบ
password	varchar(255)			รหัสผ่านผู้ใช้งาน
date_joined	timestamp			
is_active	boolean		True/False	สถานะการใช้งานของบัญชีผู้ใช้
is_staff	boolean		True/False	สถานะผู้ดูแลระบบ
name	varchar(255)			ชื่อของผู้ใช้งาน
profile_image	varchar(255)			ที่อยู่ของรูปโปรไฟล์ผู้ใช้งาน



ตารางที่ 18 ตารางพจนานุกรมของแหล่งจัดเก็บข้อมูลเพิ่มข้อมูลประเภทของผักและผลไม้

accepts: เพิ่มข้อมูลประเภทของผักและผลไม้				
Field Name	Data Type	Key type	Permissible value	Description
id	bigint (20)	PK		รหัสของผักหรือผลไม้ (Primary Key)
category	varchar(20)			ประเภทของผักหรือผลไม้
name	varchar(30)			ชื่อของผักหรือผลไม้
flavors	varchar(30)			รสชาติของผักหรือผลไม้
tips	text	Nullable		คำแนะนำในการรับประทานหรือการเลือกผักหรือผลไม้
benefits	text	Nullable		ประโยชน์ของผักหรือผลไม้
storage_instruction	text	Nullable		วิธีเก็บรักษาผักหรือผลไม้

ตารางที่ 19 ตารางพจนานุกรมของแหล่งจัดเก็บข้อมูลเพิ่มข้อมูลเมนูของผักและผลไม้

accepts: เพิ่มข้อมูลเมนูของผักและผลไม้				
Field Name	Data Type	Key type	Permissible value	Description
id	bigint (20)	PK		รหัสเมนู (Primary Key)
menu_title_ENG	varchar(200)			ชื่อเมนู (ภาษาอังกฤษ)
menu_title_TH	varchar(200)			ชื่อเมนู (ภาษาไทย)
menu_description	text			รายละเอียดของเมนู
menu_link	URLField	Nullable		ลิงก์ไปยังเมนูหรือสูตรอาหาร
menu_image	URLField	Nullable		URL รูปภาพของเมนู
food_id	bigint (20)	FK		เชื่อมโยงกับ FruitsV (ผัก/ผลไม้ที่ใช้ในเมนู)

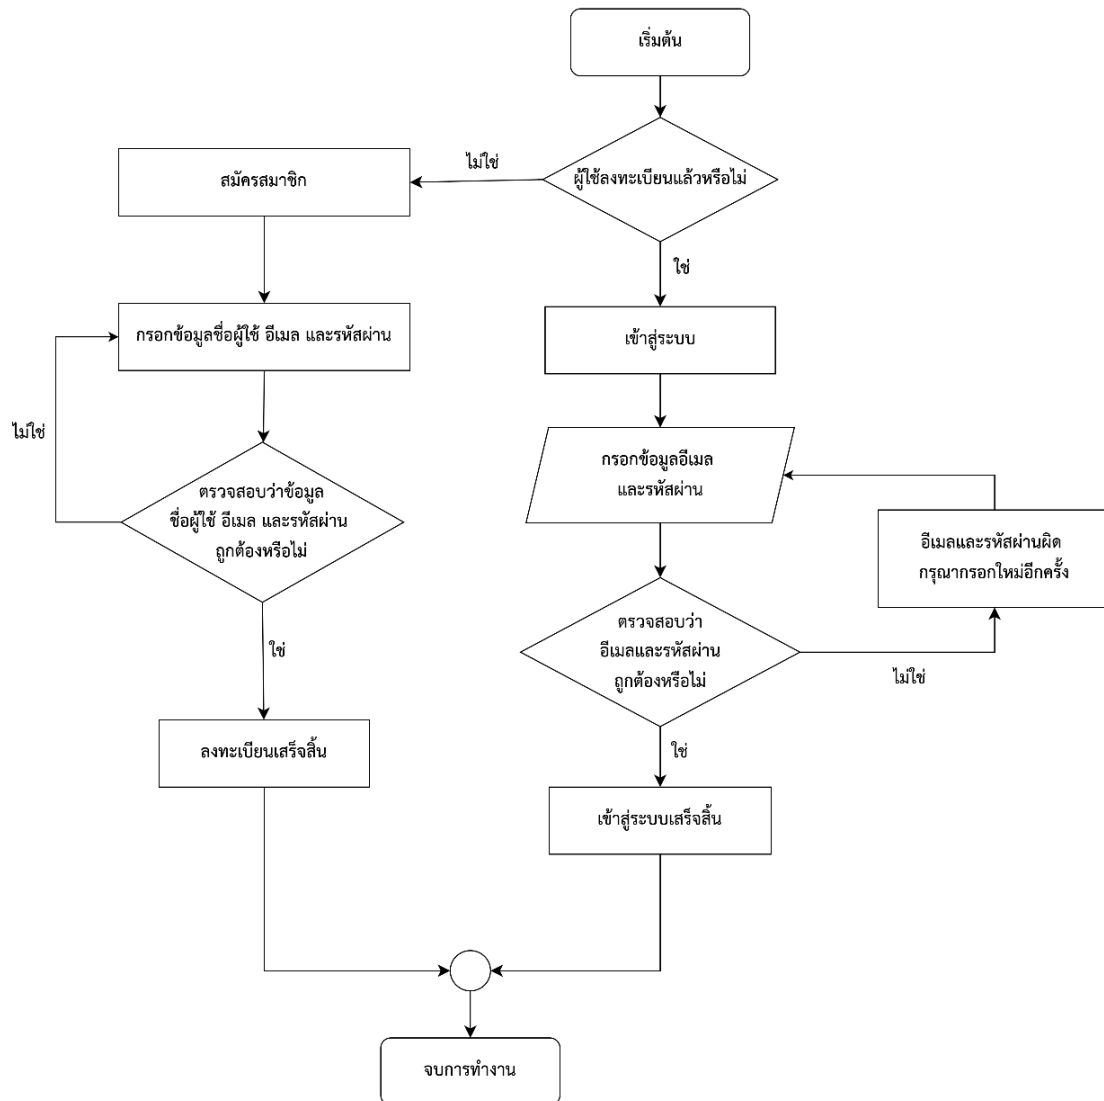


ตารางที่ 20 ตารางพจนานุกรมของแหล่งจัดเก็บข้อมูลเพิ่มข้อมูลปัญหาการใช้งานของผู้ใช้

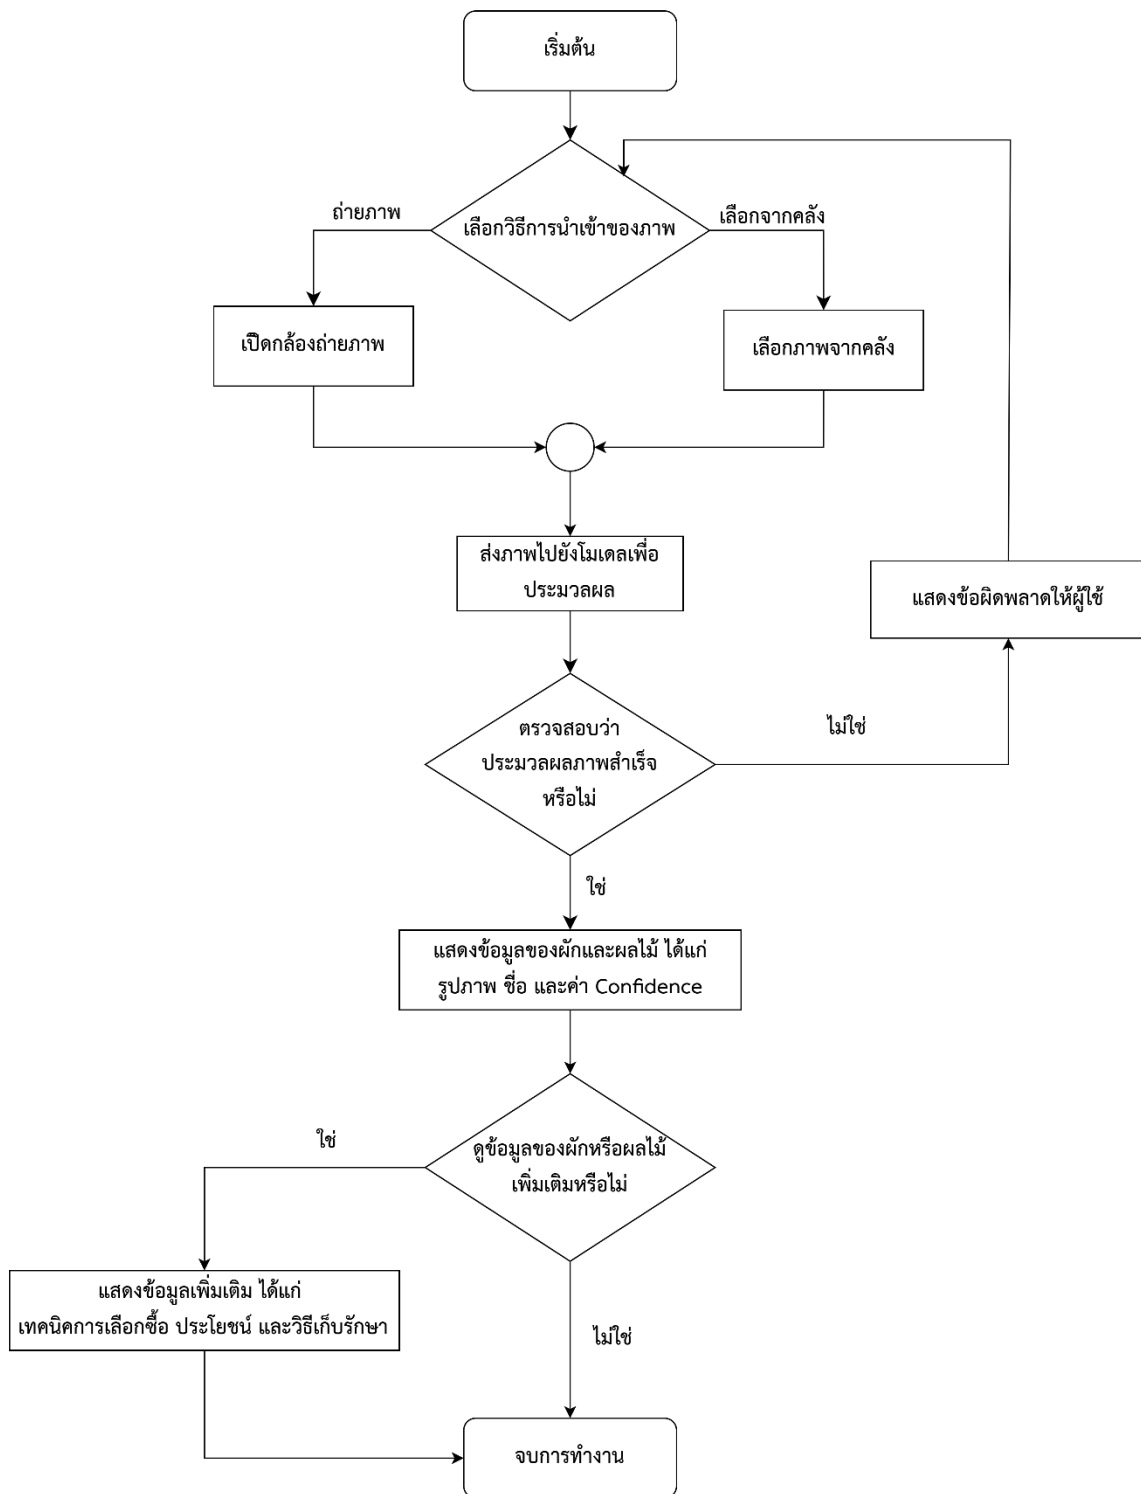
accepts: เพิ่มข้อมูลเมนูปัญหาการใช้งานของผู้ใช้				
Field Name	Data Type	Key type	Permissible value	Description
id	bigint (20)	PK		รหัสรายงานปัญหา (Primary Key)
user_id	bigint (20)	FK		ผู้ใช้ที่รายงานปัญหา
problem_type	varchar(255)			ประเภทของปัญหาที่ รายงาน ได้แก่ Scanning does not work - ปัญหาเกี่ยวกับการสแกนไม่สามารถทำงานได้ Result is not accurate - ปัญหาที่ผลลัพธ์ไม่แม่นยำหรือคลาดเคลื่อน App crashed - ปัญหาเกี่ยวกับแอปพลิเคชันหยุดทำงานกะทันหัน Other - ปัญหาอื่น ๆ ที่ไม่อยู่ในตัวเลือกข้างต้น โดยผู้ใช้สามารถระบุรายละเอียดเพิ่มเติมได้
other_details	text			รายละเอียดเพิ่มเติมเกี่ยวกับปัญหานั้น
created_at	timestamp	Nullable		วันที่และเวลาที่รายงานปัญหา

5.1.6 แผนผังขั้นตอนการทำงาน (Flow Chart)

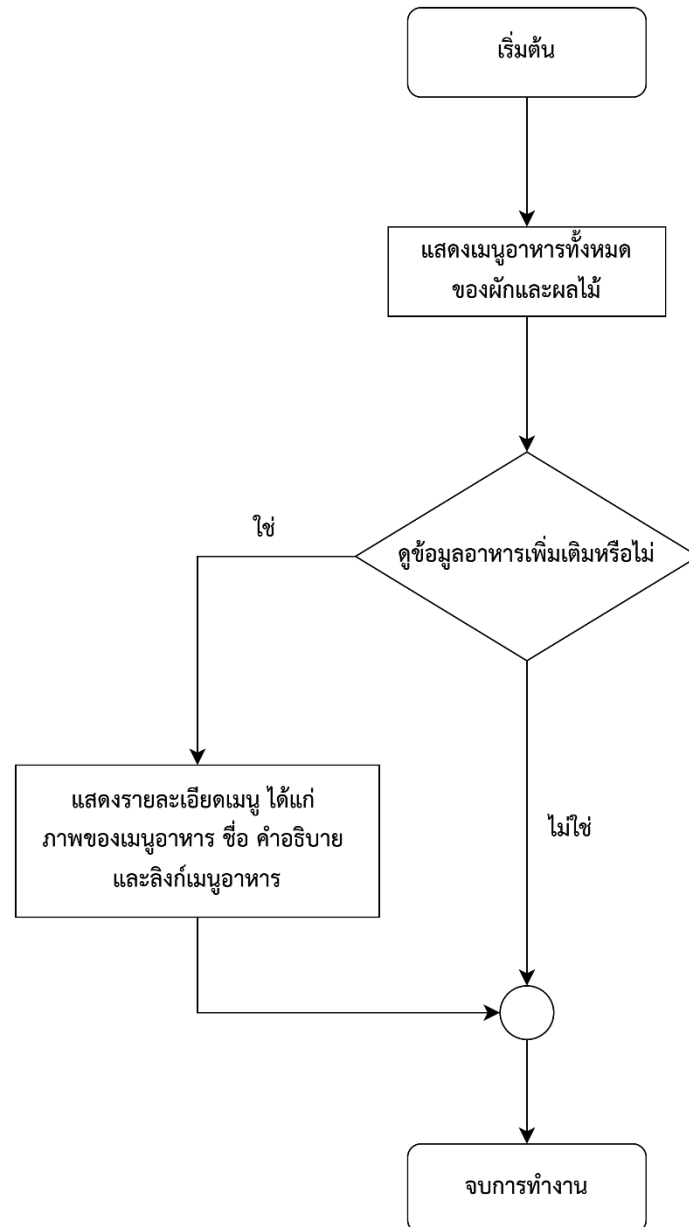
1. แผนผังการทำงานของผู้ใช้



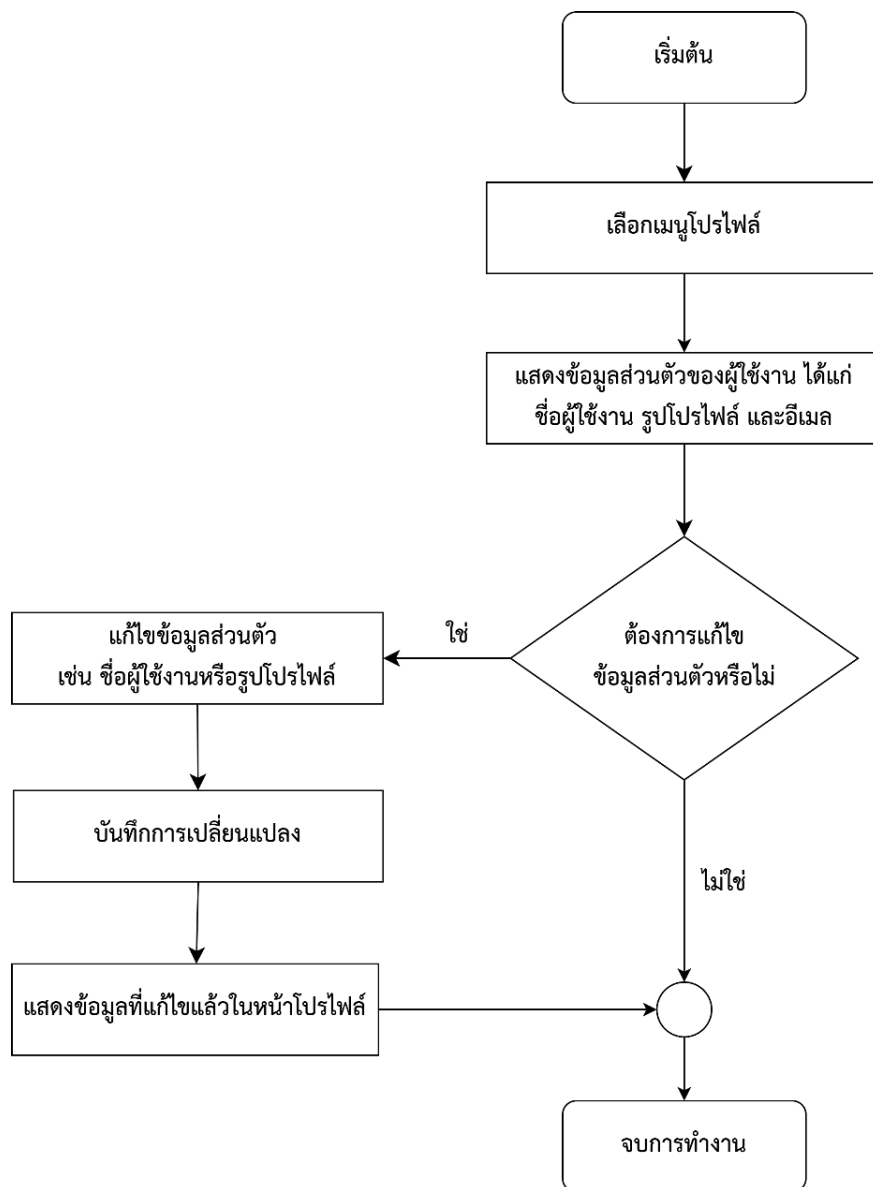
ภาพที่ 17 แผนผังการสมัครสมาชิกและการเข้าสู่ระบบ



ภาพที่ 18 แผนผังการประมวลผลภาพและแสดงข้อมูล



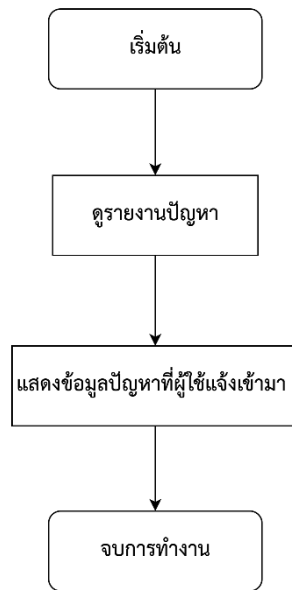
ภาพที่ 19 แผนผังการเลือกดูรายการอาหาร



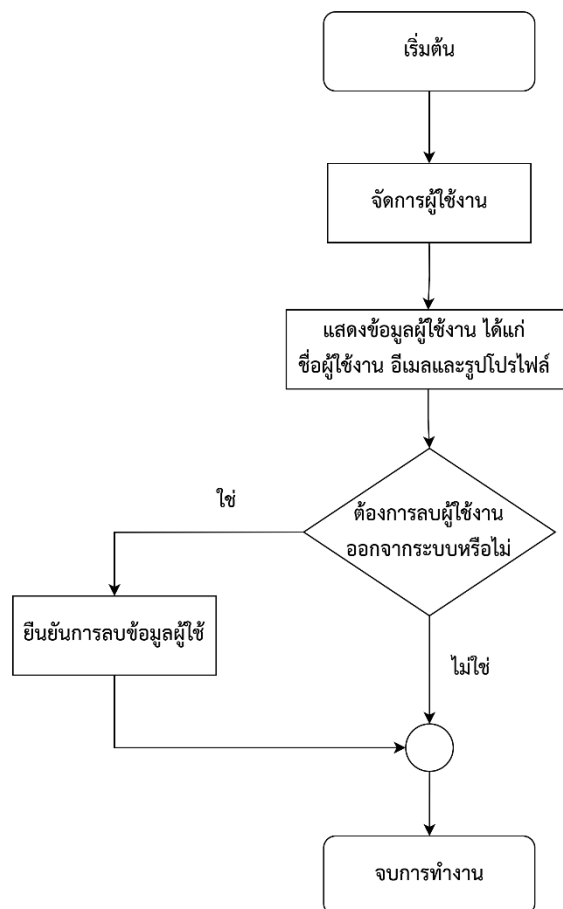
ภาพที่ 20 แผนผังการทำงานของหน้าโปรไฟล์



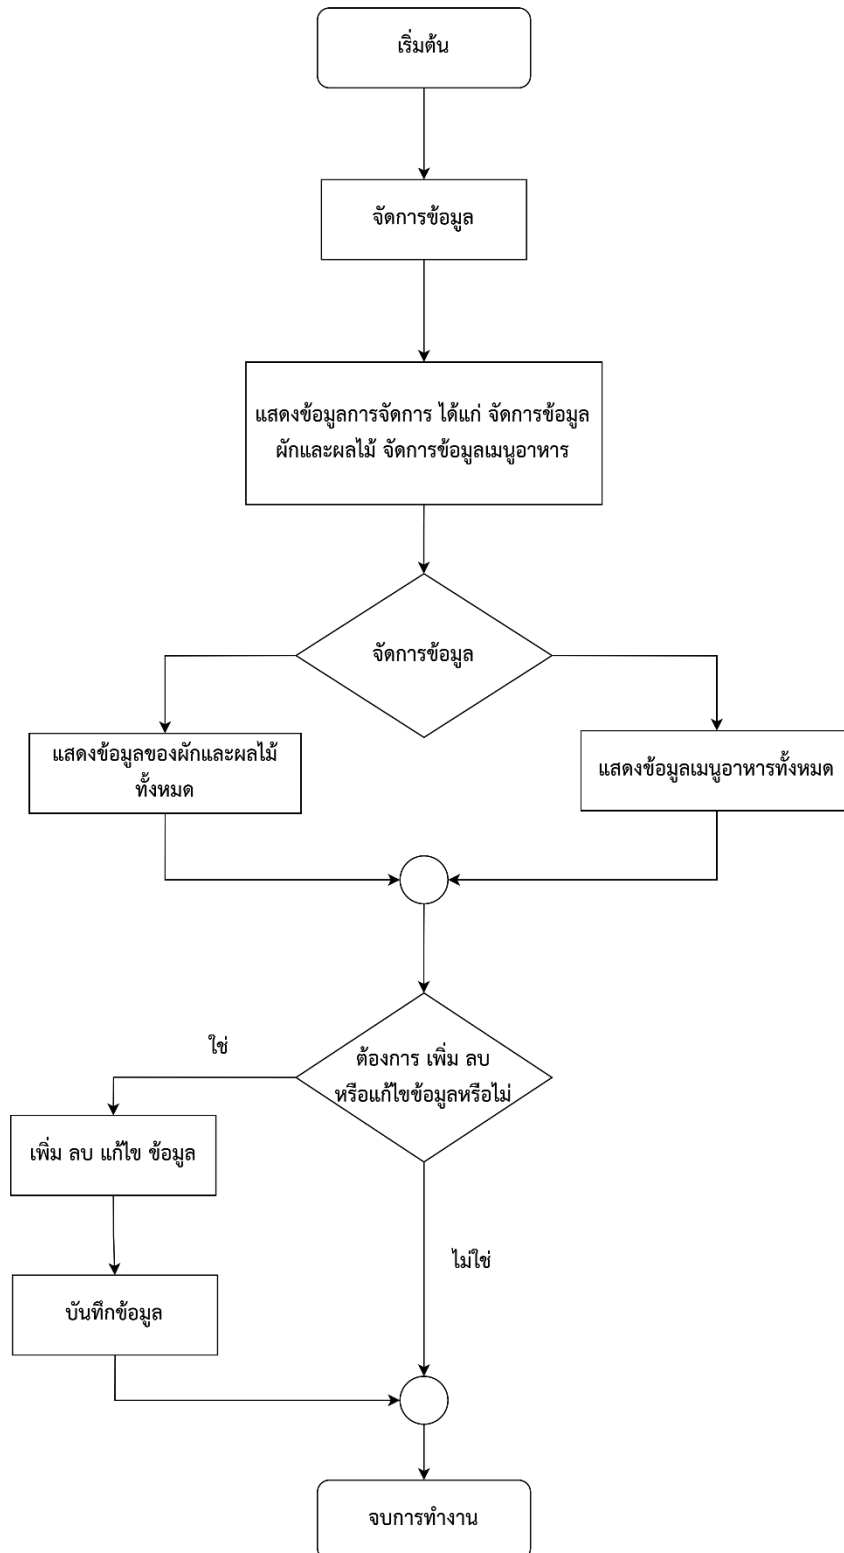
5.1.6.2 แผนผังการทำงานของผู้ดูแลระบบ



ภาพที่ 21 แผนผังการทำงานของหน้าดูรายงานปัญหา



ภาพที่ 22 แผนผังการทำงานของหน้าจัดการข้อมูลผู้ใช้



ภาพที่ 23 แผนผังการทำงานของหน้าจัดการข้อมูล



5.2 การเก็บรวบรวมข้อมูล การเก็บรวบรวมข้อมูลสำหรับการพัฒนาแอปพลิเคชันจำแนกผักและผลไม้มีรายละเอียดดังนี้

5.2.1 ชุดข้อมูลทั้งหมด ในการจำแนกประเภทผักและผลไม้ ใช้ชุดข้อมูลจากแหล่งที่เชื่อถือได้จาก Kaggle.com ได้แก่

1. ชุดข้อมูลของ Vegetable Image Dataset ประกอบด้วยภาพผักจำนวน 21,000 ภาพ แบ่งออกเป็น 15 ประเภท (Labels)
2. ชุดข้อมูลของ Fruits-262 ประกอบด้วยภาพผลไม้จำนวน 225,640 ภาพ แบ่งออกเป็น 262 ประเภท (Labels)

5.2.2 การแบ่งข้อมูล อัตราส่วน 80:20 จากภาพทั้งหมด 9,466 ภาพ โดยแบ่งข้อมูลสำหรับการฝึกสอน (Training Data) 7,572 ภาพ และข้อมูลการทดสอบ (Test Data) 1,894 ภาพ

ตารางที่ 21 รายละเอียดของชุดข้อมูลภาพผักและผลไม้

ลำดับที่	ชนิด	ชุดข้อมูล	
		สอน	ทดสอบ
1	Bitter gourd มะระขี้นก	960	240
2	Cabbage กะหล่ำปลี	800	200
3	Cauliflower กะหล่ำดอก	960	240
4	White radish หัวไชเท้าขาว	960	240
5	Custard apple น้อยหน่า	820	206
6	Dragon fruit แก้วมังกร	661	166
7	Mangosteen มังคุด	768	192
8	Rambutan เงาะ	867	217
9	Salak สลละ	776	193
รวมทั้งหมด		7,572	1,894






5.2.3 ชุดข้อมูลที่ใช้ ชุดข้อมูลที่ใช้ในการฝึกและทดสอบโมเดลของแอปพลิเคชันจำแนกผักและผลไม้ ประกอบด้วยภาพถ่ายของผัก 4 ชนิด และผลไม้ 5 ชนิด ได้แก่

1. มะระขี้นก (Bitter Gourd)
2. ดอกกะหล่ำ (Cauliflower)
3. กะหล่ำปลี (Cabbage)
4. หัวไชเท้าขาว (White Radish)
5. น้อยหน่า (Custard Apple)
6. แก้วมังกร (Dragon Fruit)
7. เงาะ (Rambutan)
8. สลละ (Salak)
9. มังคุด (Mangosteen)

ตารางที่ 22 ตัวอย่างของชุดข้อมูลผัก

ชื่อผัก	ภาพตัวอย่าง	ชื่อผัก	ภาพตัวอย่าง
มะระขี้นก		กะหล่ำปลี	
กะหล่ำดอก		หัวไชเท้าขาว	

ตารางที่ 23 ตัวอย่างของชุดข้อมูลผลไม้

ชื่อผลไม้	ภาพตัวอย่าง	ชื่อผลไม้	ภาพตัวอย่าง
น้อยหน่า		สละ	
แก้วมังกร		มังคุด	
เงาะ			

5.2.4 Normalize

เป็นขั้นตอนในการเตรียมข้อมูลสำหรับการฝึกโมเดล ซึ่งช่วยปรับค่าในภาพให้อยู่ในช่วงที่สมดุล ลดปัญหา ค่า Outliers และเพิ่มประสิทธิภาพในการเรียนรู้ของโมเดล ในงานนี้ได้ใช้วิธี Z-score normalization โดยอิงตาม ค่าเฉลี่ย (mean) และส่วนเบี่ยงเบนมาตรฐาน (std) ของพิกเซลจากชุดข้อมูลฝึก (Training Data) ซึ่งวิธีการนี้จะ ทำให้การกระจายตัวของข้อมูลมีค่าเฉลี่ยอยู่ที่ 0 และปรับให้ข้อมูลมีการกระจายตัวที่ใกล้เคียงกันมากขึ้น ช่วยให้ โมเดลสามารถเรียนรู้จากภาพได้ดีและลดความแปรปรวนที่ไม่จำเป็นในข้อมูล โดยคำนวณได้ดังต่อไปนี้

$$Z = \frac{x - \mu}{\sigma}$$

โดยที่ x คือ ค่าข้อมูลต้นฉบับ

μ ค่าเฉลี่ยของข้อมูล

σ ส่วนเบี่ยงเบนมาตรฐาน

จากการคำนวณในชุดข้อมูลภาพที่ใช้ฝึก ได้ค่า mean และ std ดังนี้

- ค่า mean คือ [0.5739, 0.5496, 0.4559]
- ค่า std คือ [0.2611, 0.2763, 0.2898]

5.2.5 Data Augmentation

การขยายชุดข้อมูลภาพเพื่อเพิ่มความหลากหลาย ช่วยให้โมเดลได้เรียนรู้จากข้อมูลในหลายรูปแบบ โดยในงานนี้ได้ใช้เทคนิคการเพิ่มข้อมูล (Data Augmentation) เพื่อสร้างตัวอย่างที่แตกต่างกันของข้อมูลภาพ เช่น การครอบภาพ (Crop) และการหมุนภาพ (Rotate) ภาพจะแสดงลำดับการแปลง ได้แก่ ภาพต้นฉบับ (Original), การครอบแบบสุ่ม (Random Crop), และการหมุนแบบสุ่ม (Random Rotate)





5.3 การทดสอบและประเมินผล (Testing and Evaluation)

5.3.1 Cross Validation

เป็นเทคนิคที่ช่วยประเมินประสิทธิภาพของโมเดลมีความน่าเชื่อถือและลดความเอนเอียงที่อาจเกิดจากการแบ่งชุดข้อมูลครั้งเดียว ในงานนี้ได้ใช้เทคนิค k-Fold Cross-Validation ซึ่งทำการแบ่งข้อมูลออกเป็น k ส่วนย่อย (folds) กำหนดให้มีการแบ่งชุดข้อมูลเป็น 5 folds โดยแบ่งข้อมูลทั้งหมดออกเป็นสองชุด คือ ชุดข้อมูลฝึก (Training Data) 80% และชุดข้อมูลทดสอบ (Testing Data) 20%

ตารางที่ 24 ผลลัพธ์การประเมินประสิทธิภาพของโมเดลจากการใช้ k-Fold Cross-Validation

Folds	Training Accuracy	Testing Accuracy	Training Loss	Testing Loss
1	73.90	74.86	0.73	0.73
2	74.17	75.66	0.72	0.70
3	73.41	71.97	0.74	0.82
4	73.39	75.48	0.74	0.69
5	75.22	76.01	0.70	0.70

การประเมินประสิทธิภาพของโมเดล

- **Loss:** ค่าความสูญเสีย (Loss) จะบ่งบอกถึงความผิดพลาดในการทำนายของโมเดล ยิ่งค่า Loss ต่ำเท่าใด โมเดลก็ยิ่งมีความสามารถในการเรียนรู้ที่ดีขึ้นและทำนายได้แม่นยำมากขึ้น
- **Accuracy:** ความแม่นยำ (Accuracy) เป็นการวัดเปอร์เซ็นต์ของการทำนายที่ถูกต้อง ยิ่งค่า Accuracy สูง โมเดลก็ยิ่งมีความสามารถในการทำนายที่ดี

จากผลลัพธ์การทดสอบ 5-fold cross-validation แสดงให้เห็นว่าโมเดลมีความแม่นยำและค่าการสูญเสียที่ดีในหลายๆ รอบ โดยใน Folds ที่ 1 ถึง 4 ความแม่นยำในชุดทดสอบ (Testing Accuracy) มีการผันผวนระหว่าง 71% ถึง 75% ขณะที่ใน Folds ที่ 5 โมเดลมีความแม่นยำสูงสุดที่ 76.01% และค่าการสูญเสีย (Testing Loss) อยู่ที่ 0.70 ซึ่งบ่งชี้ว่าโมเดลสามารถทำงานได้ดีขึ้นในรอบสุดท้าย

ดังนั้น ผลการทดสอบแสดงให้เห็นว่าโมเดลมีประสิทธิภาพการเรียนรู้ที่ดีขึ้นในชุดข้อมูลทดสอบ โดยเฉพาะใน Folds ที่ 5 ซึ่งมีค่า Testing Accuracy สูงสุด ส่งผลให้โมเดลสามารถจำแนกข้อมูลได้อย่างแม่นยำขึ้นในชุดข้อมูลทดสอบ

5.4 ผลการประเมินประสิทธิภาพ (Performance Evaluation)

5.4.1 Confusion Matrix

ในการจำแนกชนิดผักและผลไม้ได้ประยุกต์ใช้ร่วมกับสถาปัตยกรรม CNN โดยทำการปรับแต่งโมเดลเพื่อหาผลการเรียนรู้ที่มีประสิทธิภาพที่ดี โดยทำการประเมินประสิทธิภาพโมเดลด้วย confusion matrix กับชุดข้อมูลทดสอบ 20 เปอร์เซนต์จากข้อมูลทั้งหมด จากนั้นนำข้อมูลสำหรับประเมินประสิทธิภาพแต่ละหมวดหมู่ หาค่าความแม่นยำ (Precision), ค่าความระลึก (Recall), ค่าความถูกต้อง (Accuracy) ผลลัพธ์การจำแนกชนิดจะแสดงรายละเอียดทั้งหมด ดังนี้



	precision	recall	f1-score	support
Bitter Gourd	0.91	0.96	0.93	240.00
Cabbage	0.95	0.94	0.95	200.00
Cauliflower	0.93	0.87	0.90	240.00
Custard Apple	0.76	0.68	0.72	206.00
Dragon Fruit	0.94	0.87	0.90	166.00
Mangosteen	0.88	0.84	0.86	192.00
White Radish	0.98	0.99	0.99	240.00
Rambutan	0.78	0.96	0.86	217.00
Salak	0.88	0.87	0.87	193.00
accuracy	0.89	0.89	0.89	0.89
macro avg	0.89	0.89	0.89	1894.00
weighted avg	0.89	0.89	0.89	1894.00

ภาพที่ 24 ผลลัพธ์การประเมินประสิทธิภาพโมเดล

คลาสที่มีค่า Precision ที่น้อยที่สุด คือ น้อยหน่า (Custard Apple) อยู่ที่ 0.76 อาจเป็นเพราะรูปร่างของผลไม้คล้ายกับผักชนิดอื่น เช่น กะหล่ำดอก (Cauliflower) ทำให้โมเดลแยกแยะได้ยาก และรูปภาพส่วนใหญ่ในชุดข้อมูลสลับไปกับสภาพแวดล้อม อีกทั้งบางภาพของน้อยหน่าในชุดข้อมูลมีสีเข้ม ซึ่งอาจทำให้โมเดลไม่สามารถเรียนรู้รายละเอียดที่สำคัญในการจำแนกผลไม้ชนิดนี้ได้เท่าที่ควร


คลาสที่มีค่า Precision ที่สูงที่สุด คือ หัวไชเท้าขาว (White Radish) อยู่ที่ 0.98 เพราะลักษณะเฉพาะที่ชัดเจน ทำให้โมเดลสามารถจดจำและแยกแยะได้ง่าย ด้วยสีของหัวไชเท้าที่เป็นสีขาวทั้งหมด จึงทำให้โมเดลเรียนรู้ลักษณะนี้ได้ดี

คลาสที่มีค่า Recall ที่น้อยที่สุด คือ น้อยหน่า (Custard Apple) อยู่ที่ 0.68 เพราะลักษณะของน้อยหน่าคล้ายกะหล่ำดอก โดยทั้งสองมีผิวภายนอกที่ขรุขระคล้ายกัน ซึ่งอาจทำให้โมเดลสับสนและจำแนกผิดเป็นกะหล่ำดอกได้ ความแตกต่างที่ชัดเจนคือกะหล่ำดอกจะมีขั้วอยู่ข้างใต้ ซึ่งอาจช่วยให้โมเดลแยกแยะได้ดีขึ้น หากภาพในชุดข้อมูลมีความชัดเจนในลักษณะนี้ หากเพิ่มภาพที่แสดงลักษณะเฉพาะนี้มากขึ้น โมเดลอาจจะสามารถแยกแยะน้อยหน่า

คลาสที่มี Recall ที่สูงที่สุด คือ หัวไชเท้าขาว (White Radish) อยู่ที่ 0.99 เพราะลักษณะเฉพาะที่ชัดเจน ทำให้โมเดลสามารถจดจำและแยกแยะได้ง่าย ด้วยสีของหัวไชเท้าที่เป็นสีขาวทั้งหมด จึงทำให้โมเดลเรียนรู้ลักษณะนี้ได้ดี

คลาสที่มีค่า F1-Score ที่น้อยที่สุด คือ น้อยหน่า (Custard Apple) อยู่ที่ 0.72 เพราะน้อยหนามีค่า Precision และ Recall ที่ต่ำ เนื่องจากชุดข้อมูลไม่สามารถแสดงลักษณะเด่นของผลไม้ชนิดนี้ออกมาได้อย่างชัดเจน ทำให้ไม่สามารถเรียนรู้ข้อแตกต่างระหว่างน้อยหน่ากับกะหล่ำดอกหรือกับผักและผลไม้ชนิดอื่นที่มีรูปร่างและสีคล้ายกันได้ ส่งผลให้การทำนายมีความถูกต้องที่ต่ำ

คลาสที่มีค่า F1-Score ที่สูงที่สุด คือ หัวไชเท้าขาว (White Radish) อยู่ที่ 0.99 เพราะลักษณะเฉพาะที่ชัดเจน ทำให้โมเดลสามารถจดจำและแยกแยะได้ง่าย ด้วยสีของหัวไชเท้าที่เป็นสีขาวทั้งหมด จึงทำให้โมเดลเรียนรู้ลักษณะนี้ได้ดี



ภาพที่ 25 ผลลัพธ์ Confusion Matrix ของ CNN Model

ในภาพนี้เป็น **Confusion Matrix** ที่แสดงถึงประสิทธิภาพของโมเดลในการจำแนกประเภทผลไม้และผักชนิดต่าง ๆ โดยรายละเอียดของแต่ละส่วนมีดังนี้

ค่าในแนวทแยง (เส้นทแยงจากบนซ้ายลงล่างขวา) ตัวเลขในแนวทแยงจะแสดงถึงจำนวนตัวอย่างที่โมเดลทำนายได้ถูกต้อง เช่น "มะระขี้นก" (Bitter Gourd) ทำนายถูกต้อง 350 ตัวอย่าง, "กะหล่ำปลี" (Cabbage) ทำนายถูก 189 ตัวอย่าง, และ "หัวไชเท้า" (White Radish) ทำนายถูกต้องมากที่สุดที่ 237 ตัวอย่าง ซึ่งยิ่งจำนวนในแนวทแยงมีมากแสดงว่าโมเดลทำนายคลาสนั้นได้ดี

ค่าอื่น ๆ ที่ไม่อยู่ในแนวทแยง ตัวเลขที่อยู่ในส่วนอื่น ๆ นอกแนวทแยงจะบอกถึงการทำนายผิดพลาด เช่น โมเดลทำนาย "น้อยหน่า" (Custard Apple) เป็น "กะหล่ำดอก" (Cauliflower) จำนวน 22 ตัวอย่าง และทำนาย "แก้วมังกร" (Dragon Fruit) เป็น "เงาะ" (Rambutan) จำนวน 20 ตัวอย่าง ค่าเหล่านี้ช่วยบอกว่าโมเดลสับสนระหว่างคลาสไหนบ้าง ซึ่งสามารถนำไปปรับปรุงให้โมเดลดีขึ้นได้

การสับสนระหว่างบางคลาส ความสับสนของโมเดลในการแยกบางคลาส อาจเกิดจากลักษณะที่คล้ายกัน เช่น

- "กะหล่ำดอก" (Cauliflower) และ "น้อยหน่า" (Custard Apple) มีการทำนายผิดพลาดระหว่างกัน อาจเป็นเพราะลักษณะภายนอกของผักทั้งสองชนิดมีลักษณะผิวขรุขระหรือเป็นปุ่ม ๆ ทำให้โมเดลสับสนได้
- "เงาะ" (Rambutan) และ "สละ" (Salak) มีการทำนายผิดระหว่างกันเนื่องจากทั้งสองชนิดมีผิวเปลือกที่มีหนามและสีแดงเข้มที่คล้ายคลึงกัน



จากผลการประเมินประสิทธิภาพพบว่า Accuracy ของโมเดล 0.89 หรือ 89% ซึ่งมีประสิทธิภาพที่ดี โดยพิจารณาจากค่าความแม่นยำ (Precision), ค่าความระลึก (Recall), ค่าความถูกต้อง (Accuracy) ดังนั้นในงานนี้จึงนำโมเดลนี้ไปใช้กับการสร้าง Mobile Application จำแนกผักและผลไม้

5.4 แผนดำเนินงาน (Plan Project)

แผนการดำเนินงานในการพัฒนาระบบสารสนเทศ สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาวิทยาการคำนวณและเทคโนโลยีดิจิทัล คณะศิลปศาสตร์และวิทยาศาสตร์ มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตกำแพงแสน ระยะเวลาในการพัฒนาระบบ ตั้งแต่ มกราคม พ.ศ.2567 ถึง ตุลาคม พ.ศ.2567 โดยแต่ละขั้นตอนกำหนดระยะเวลา ดังนี้

ตารางที่ 25 ตารางการดำเนินงาน

ลำดับ	ขั้นตอนการดำเนินงาน	พ.ศ. 2567									
		ม.ค.	ก.พ.	มี.ค.	เม.ย.	พ.ค.	มิ.ย.	ก.ค.	ส.ค.	ก.ย.	ต.ค.
1	ศึกษาระบบและวิจัยที่เกี่ยวข้อง										
2	รวบรวมทฤษฎีในการทำโครงการ										
3	การวิเคราะห์และรวบรวมข้อมูลฝึกอบรม										
4	พัฒนาและปรับปรุงอัลกอริทึม										
5	ทดสอบอัลกอริทึม										
6	การออกแบบและทดสอบ UI/UX										
7	ออกแบบระบบ ฐานข้อมูล										
8	การพัฒนาแอปพลิเคชัน										
9	ทดสอบและปรับปรุงระบบ										
10	จัดทำคู่มือและเอกสารประกอบ										

6. ผลการดำเนินงาน (Results)

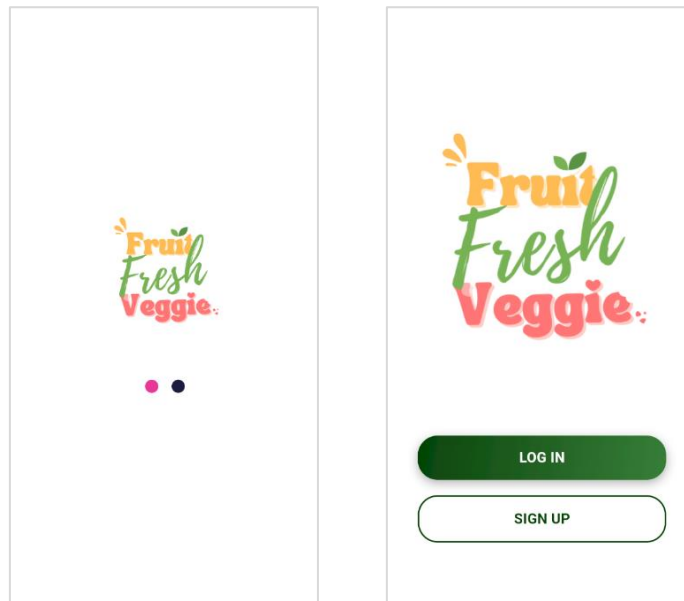
จากการออกแบบระบบแอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์ โดยมีจุดมุ่งหมายเพื่อช่วยเพิ่มประสิทธิภาพและเพิ่มสะดวกในการเข้าถึงมากยิ่งขึ้น ซึ่งปรากฏผลตามวัตถุประสงค์ดังนี้

6.1 ผลการพัฒนาแอปพลิเคชันมือถือสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์

6.1.1 ส่วนหน้าผู้ใช้ (User Interface / User Experience)

6.1.1.1 หน้าโหลด (Loading Page) และหน้าแรก (Welcome Page)

หน้าโหลด คือหน้าจอที่แสดงขณะรอให้แอปพลิเคชันทำการโหลดข้อมูล เป็นการแสดงภาพเคลื่อนไหวหรือโลโก้ของแอป เพื่อให้ผู้ใช้ทราบว่าแอปพลิเคชันกำลังเตรียมพร้อมใช้งาน จากนั้นจะนำไปสู่หน้าแรก เพื่อให้ผู้ใช้เลือกที่จะสมัครสมาชิกหรือเข้าสู่ระบบ

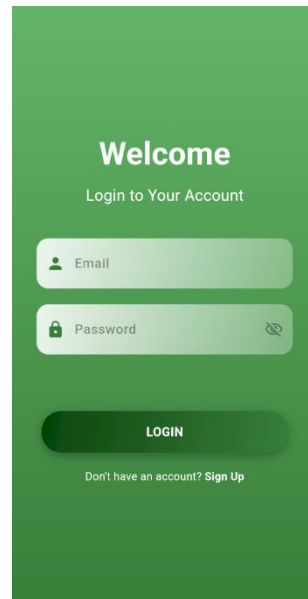


ภาพที่ 26 หน้าโหลด และหน้าแรก



6.1.1.2 หน้าจอเข้าสู่ระบบ (Login Screen)

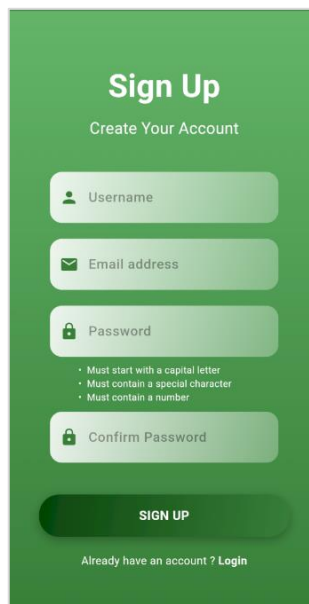
เป็นหน้าที่ผู้ใช้ต้องกรอกข้อมูล เช่น อีเมล (Email) และรหัสผ่าน (Password) ก่อนเข้าใช้งานแอปพลิเคชัน

A login screen with a green background. At the top, it says "Welcome" in white, followed by "Login to Your Account" in a smaller white font. Below this are two white input fields: "Email" with a person icon and "Password" with a lock icon and a toggle eye icon. A green "LOGIN" button is centered below the fields. At the bottom, it says "Don't have an account? Sign Up" in white.

ภาพที่ 27 หน้าจอเข้าสู่ระบบ

6.1.1.3 หน้าจอสมัครสมาชิก (Sign Up Screen)

เป็นหน้าที่ผู้ใช้ใหม่จะต้องกรอกข้อมูลส่วนตัว เช่น ชื่อผู้ใช้ รหัสผ่าน และอีเมล เพื่อลงทะเบียนบัญชีใหม่ เมื่อสมัครเสร็จแล้ว ผู้ใช้จะสามารถเข้าสู่ระบบและเริ่มใช้งานแอปพลิเคชันได้

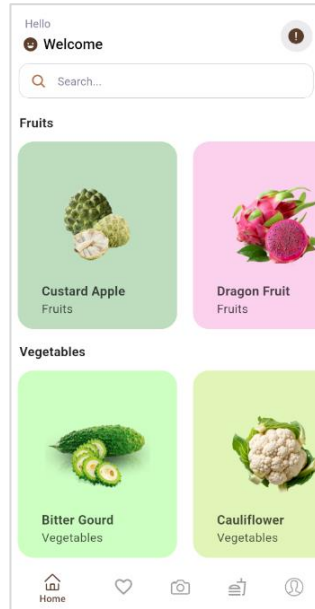
A sign up screen with a green background. At the top, it says "Sign Up" in white, followed by "Create Your Account" in a smaller white font. Below this are four white input fields: "Username" with a person icon, "Email address" with an envelope icon, "Password" with a lock icon, and "Confirm Password" with a lock icon. Below the password fields are three bullet points: "• Must start with a capital letter", "• Must contain a special character", and "• Must contain a number". A green "SIGN UP" button is centered below the fields. At the bottom, it says "Already have an account ? Login" in white.

ภาพที่ 28 หน้าจอสมัครสมาชิก



6.1.1.4 หน้าหลัก (Home Page)

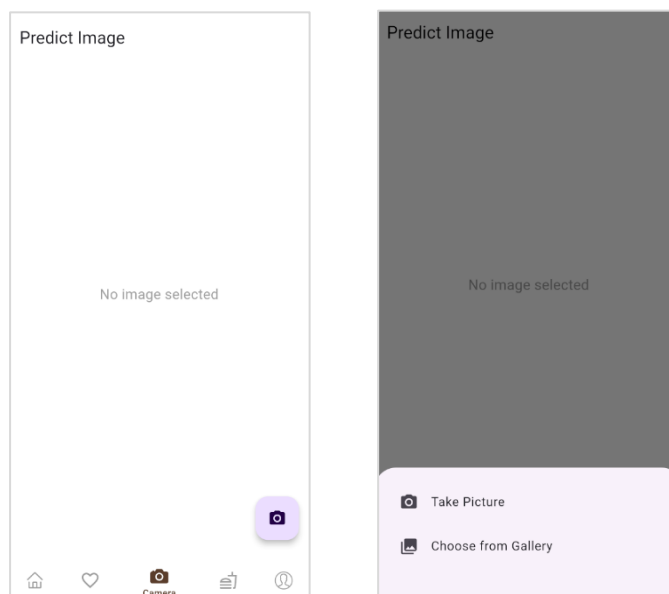
หน้าหลักจะแบ่งออกเป็น 3 ส่วน ส่วนที่หนึ่งจะเป็นช่องสำหรับการค้นหาผลไม้หรือผัก ส่วนที่สองจะเป็นรูปภาพของผลไม้ และส่วนที่สามเป็นส่วนของผัก ซึ่งสามารถกดเข้าไปดูข้อมูลต่าง ๆ ได้โดยไม่จำเป็นต้องถ่ายภาพหรืออัปโหลดรูปภาพทุกครั้ง



ภาพที่ 29 หน้าจอหลักเมื่อเข้าสู่ระบบ

6.1.1.5 หน้าถ่ายภาพ และอัปโหลดรูปภาพ

หน้าถ่ายภาพหรืออัปโหลดรูปภาพเป็นหน้าที่ให้ผู้ใช้เลือกวิธีการนำเข้าภาพของผักและผลไม้ เพื่อให้แอปพลิเคชันทำการจำแนก โดยผู้ใช้สามารถเลือกที่จะถ่ายภาพใหม่ผ่านกล้องของอุปกรณ์ หรืออัปโหลดภาพที่มีอยู่แล้วจากแกลเลอรี



ภาพที่ 30 หน้าถ่ายภาพ และอัปโหลดรูปภาพ



6.1.1.6 หน้าผลการทำนาย

หน้าผลการทำนายเป็นหน้าที่แสดงผลลัพธ์หลังจากที่ผู้ใช้ทำการถ่ายภาพหรืออัปโหลดภาพของผักและผลไม้ โดยแอปพลิเคชันจะแสดงข้อมูลที่จำแนกได้จากภาพ เช่น ชื่อและชนิดของผักหรือผลไม้ที่ตรวจพบ รวมถึงแสดงค่า confidence



ภาพที่ 31 หน้าผลการทำนาย

6.1.1.7 หน้าแสดงข้อมูล

หน้าแสดงข้อมูลเป็นหน้าที่แสดงรายละเอียดเพิ่มเติมเกี่ยวกับผักหรือผลไม้ที่ผู้ใช้สนใจ หลังจากการทำนายหรือการเลือกจากรายการผลลัพธ์แล้ว หน้านี้จะแสดงข้อมูลสำคัญ เช่น ชื่อชนิดของผักหรือผลไม้ รสชาติ วิธีการเลือกซื้อ ประโยชน์ต่อสุขภาพ และวิธีการเก็บรักษา

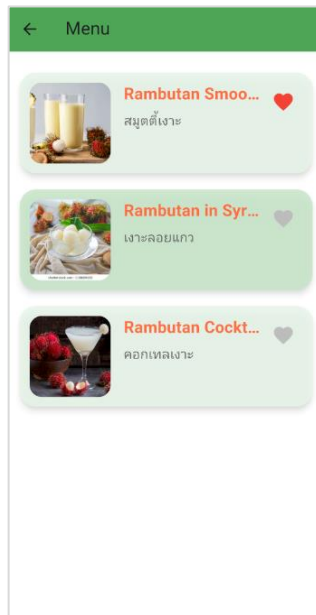


ภาพที่ 32 หน้าแสดงข้อมูล



6.1.1.8 หน้าเมนูอาหารของผักและผลไม้แต่ละชนิด

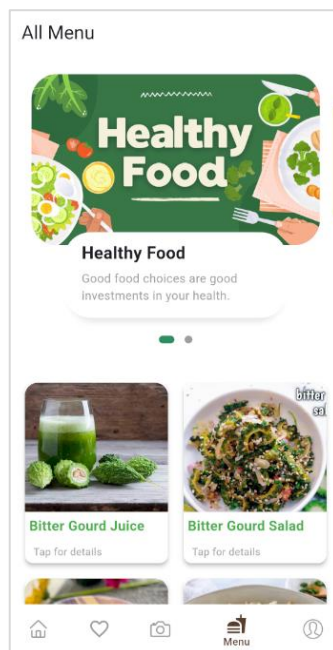
ผู้ใช้สามารถเข้าถึงเมนูอาหารของผักหรือผลไม้แต่ละชนิดได้หลังจากทำนาย โดยแต่ละเมนูจะแสดงรายละเอียด ได้แก่ ชื่อเมนู และรูปภาพประกอบ



ภาพที่ 33 หน้าเมนูอาหารของผักและผลไม้แต่ละชนิด

6.1.1.9 หน้าเมนูอาหารทั้งหมด

ผู้ใช้สามารถเข้าถึงเมนูอาหารที่หลากหลาย โดยแต่ละเมนูจะแสดงรายละเอียด ได้แก่ ชื่อเมนู และรูปภาพประกอบ ผู้ใช้สามารถเลื่อนดูเมนูอาหารทั้งหมดที่ต้องการได้อย่างรวดเร็ว

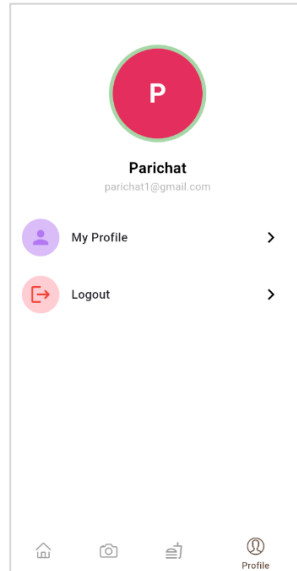


ภาพที่ 34 หน้าเมนูอาหารทั้งหมด



6.1.1.10 หน้าดูข้อมูลส่วนตัว

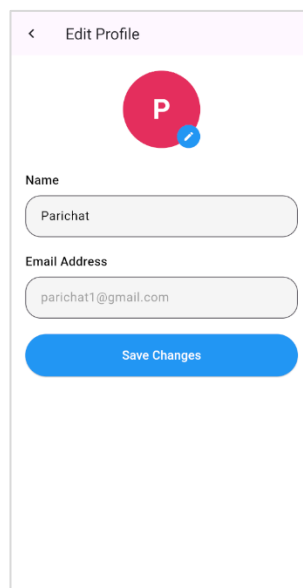
หน้าดูข้อมูลส่วนตัวเป็นหน้าที่แสดงข้อมูลของผู้ใช้ในแอปพลิเคชัน โดยผู้ใช้สามารถตรวจสอบและจัดการข้อมูลของตนได้อย่างสะดวก ในหน้านี้แสดงข้อมูลเกี่ยวกับบัญชีผู้ใช้ ประกอบไปด้วย ชื่อผู้ใช้งาน อีเมล รวมถึงปุ่มแก้ไขโปรไฟล์ และปุ่มออกจากระบบ



ภาพที่ 35 หน้าดูข้อมูลส่วนตัว

6.1.1.11 หน้าแก้ไขข้อมูลส่วนตัว

หน้าแก้ไขข้อมูลส่วนตัวเป็นหน้าที่ให้ผู้ใช้สามารถปรับปรุงข้อมูลส่วนตัวของตนได้ตามต้องการ โดยในหน้านี้ผู้ใช้สามารถเปลี่ยนแปลงชื่อที่ใช้แสดงภายในแอปพลิเคชัน และอัปโหลดหรือเปลี่ยนรูปโปรไฟล์ได้



ภาพที่ 36 หน้าแก้ไขข้อมูลส่วนตัว



6.1.1.12 หน้ารายงานปัญหา

หน้ารายงานปัญหาเป็นหน้าที่ให้ผู้ใช้สามารถแจ้งปัญหาหรือข้อบกพร่องที่เกิดขึ้นขณะใช้งานแอปพลิเคชัน ผู้ใช้สามารถเลือกประเภทปัญหาที่พบจากรายการที่ให้ โดยใช้ Dropdown Menu เพื่อให้การเลือกทำได้ง่ายและสะดวก

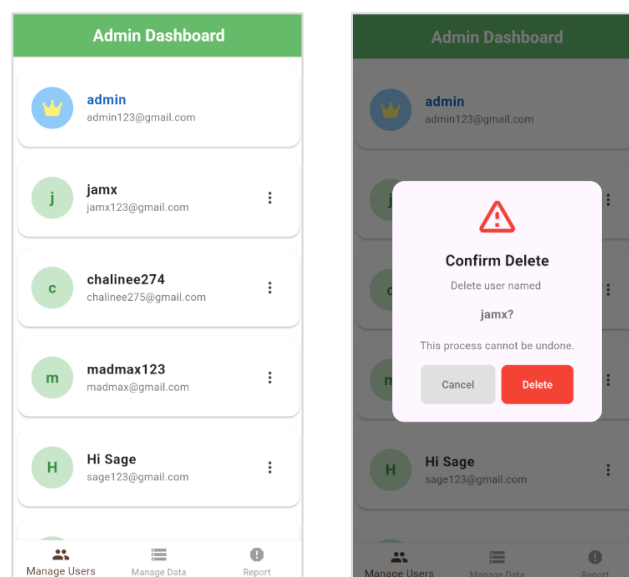
ภาพที่ 37 หน้ารายงานปัญหา

6.1.2 ส่วนหน้าผู้ดูแลระบบ (Admin Interface)

หน้าผู้ดูแลระบบเป็นหน้าจอที่ออกแบบมาเพื่อให้ผู้ดูแลสามารถจัดการผู้ใช้ในระบบได้อย่างมีประสิทธิภาพ โดยมีฟังก์ชันการทำงานต่าง ๆ เพื่อให้บริหารจัดการง่ายและสะดวกมากขึ้น ประกอบด้วย

6.1.2.1 หน้าจัดการผู้ใช้

ผู้ดูแลสามารถจัดการข้อมูลผู้ใช้ในระบบได้ โดยหน้าจอนี้จะแสดง ชื่อและอีเมลของผู้ใช้ นอกจากนี้ยังมีเมนูที่อนุญาตให้ผู้ดูแลลบผู้ใช้ออกจากระบบได้

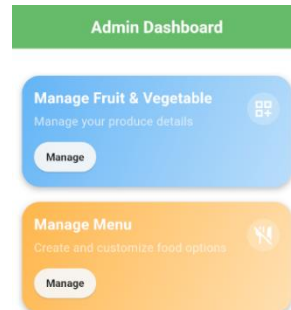


ภาพที่ 38 หน้าจัดการผู้ใช้



6.1.2.2 หน้าจัดการข้อมูล

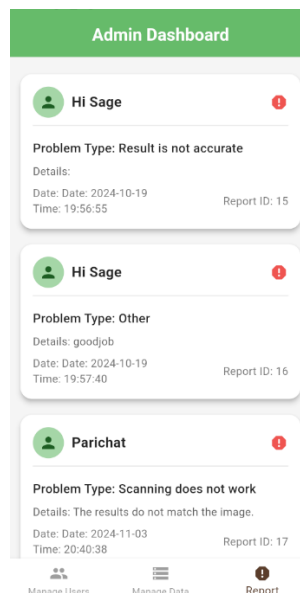
เป็นหน้าที่ออกแบบมาเพื่อให้ผู้ดูแลระบบสามารถจัดการข้อมูลภายในระบบได้ หน้าประกอบไปด้วย การจัดการข้อมูลผลไม้และผัก (Manage Fruit & Vegetable) และการจัดการเมนู (Manage Menu)



ภาพที่ 39 หน้าจัดการข้อมูล

6.1.2.3 หน้าดูปัญหาการใช้งาน

ผู้ดูแลระบบสามารถติดตามปัญหาที่เกิดขึ้นกับผู้ใช้งานในระบบ โดยมีฟังก์ชันการบันทึกและรายงานปัญหาจากผู้ใช้งาน ซึ่งจะช่วยให้ผู้ดูแลระบบทราบถึงปัญหาและแก้ไขปัญหาให้แอปพลิเคชันมีประสิทธิภาพมากยิ่งขึ้น



ภาพที่ 40 หน้าดูปัญหาการใช้งาน



7. สรุปผลและอภิปรายผล

จากการพัฒนาแอปพลิเคชันเพื่อจำแนกผักและผลไม้โดยใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) แสดงให้เห็นว่าผลลัพธ์ที่ได้รับนั้นมีความน่าพอใจ แอปพลิเคชันสามารถระบุชนิดของผักและผลไม้ได้ ซึ่งช่วยให้ผู้ใช้งานสามารถเข้าถึงข้อมูลเกี่ยวกับผักและผลไม้ รวมถึงคำแนะนำในการเลือกซื้อได้อย่างสะดวกและรวดเร็ว โดยเฉพาะในสถานะแสงและมุมกล้องที่หลากหลาย การทดสอบแสดงให้เห็นว่าการปรับปรุงชุดข้อมูลและการปรับแต่งโครงสร้างของโมเดล มีส่วนช่วยในการเพิ่มความแม่นยำในการทำนายผลได้อย่างดี แต่แอปพลิเคชันยังมีข้อจำกัดในบางกรณี เช่น การสแกนผักและผลไม้ที่มีลักษณะคล้ายกันในแง่ของสีหรือรูปร่าง ซึ่งทำให้โมเดลอาจทำนายผิดได้ เช่น การทำนายน้อยหน่าเป็นกะหล่ำดอก หรือทำนายสละเป็นเงาะ

ข้อจำกัดเหล่านี้บ่งชี้ถึงความจำเป็นในการเพิ่มความหลากหลายของภาพในชุดข้อมูล โดยการเพิ่มภาพจากมุมและสภาพแวดล้อมที่แตกต่างกัน รวมถึงการฝึกโมเดลด้วยข้อมูลที่มีการแยกแยะลักษณะของผักและผลไม้ที่คล้ายคลึงกันอย่างชัดเจน

จากการพัฒนาแอปพลิเคชันสำหรับจำแนกผักและผลไม้ด้วยปัญญาประดิษฐ์ พบว่าการใช้สถาปัตยกรรม Convolutional Neural Network (CNN) แบบ Custom ส่งผลให้ค่า Accuracy อยู่ที่ 89 เปอร์เซ็นต์ จากการประเมินประสิทธิภาพโดยการคำนวณจาก Confusion Matrix รวมถึงการเปรียบเทียบผลการทำนายสำหรับผักและผลไม้ทั้ง 9 ชนิด ผลการทดสอบแสดงให้เห็นว่าการทำนายหวัชเห่ามีประสิทธิภาพสูงสุด

แอปพลิเคชันนี้สามารถตอบสนองความต้องการของผู้ใช้งานในการระบุชนิดของผักและผลไม้ผ่านการถ่ายภาพ โดยใช้โมเดลการเรียนรู้ของเครื่องเป็นเครื่องมือในการจำแนกและแสดงข้อมูลโภชนาการเพื่อช่วยในการตัดสินใจเลือกซื้อของผู้ใช้งาน ในอนาคตสามารถพัฒนาแอปพลิเคชันให้มีประสิทธิภาพสูงขึ้นได้ โดยการขยายขอบเขตของชุดข้อมูลและปรับปรุงอัลกอริทึม เพื่อให้สามารถจำแนกผลลัพธ์ได้ในสภาพแวดล้อมที่หลากหลายมากยิ่งขึ้น

8. ข้อเสนอแนะ

- 8.1 การเลือกรูปภาพสำหรับการฝึกอบรมโมเดลจำแนกผักและผลไม้ควรมีความหลากหลาย โดยควรประกอบไปด้วยภาพที่มีพื้นหลังและสภาพแวดล้อมที่แตกต่างกัน แม้ว่าจะเป็นชนิดเดียวกัน เพื่อให้โมเดลสามารถเรียนรู้และเข้าใจรูปแบบที่หลากหลายได้มากขึ้น การมีภาพอินพุตที่หลากหลายจะช่วยเพิ่มประสิทธิภาพและความถูกต้องของโมเดลในการจำแนกชนิดของผักและผลไม้ในสภาพแวดล้อมที่แตกต่างกัน
- 8.2 การเพิ่มปริมาณชุดข้อมูลสำหรับการฝึกฝนและทดสอบ เนื่องจากคุณภาพของโมเดลขึ้นอยู่กับปริมาณและความหลากหลายของชุดข้อมูลที่ใช้ในการฝึกอบรม
- 8.3 เมื่อผู้ใช้งานแจ้งปัญหายังผู้ดูแลระบบ ผู้ดูแลระบบควรแจ้งข้อมูลหรือสถานะการดำเนินการกลับไปยังผู้ใช้ เพื่อให้ผู้ใช้งานทราบถึงความคืบหน้าในการดำเนินการ
- 8.4 ควรมีการเก็บประวัติการใช้งานของผู้ใช้ในระบบ เช่น การบันทึกภาพผักและผลไม้ที่ผู้ใช้เคยถ่ายไว้ รวมถึงข้อมูลที่เกี่ยวข้องกับการถ่ายภาพหรือการเลือกภาพในแต่ละครั้ง ซึ่งการเก็บข้อมูลนี้จะช่วยให้ผู้ใช้สามารถเข้าถึงประวัติการใช้งานของตนเองได้อย่างสะดวก โดยการให้ผู้ใช้สามารถกดดูข้อมูลที่เกี่ยวข้องเพิ่มเติม



9. ผลที่คาดว่าจะได้รับ (Expected Benefits)

- 9.1 การพัฒนาโมเดลการเรียนรู้ของเครื่อง (Machine Learning) จะเป็นพื้นฐานในการนำไปใช้ในแอปพลิเคชันอื่น ๆ ในอนาคต ซึ่งช่วยเพิ่มความสะดวกในการใช้งานในด้านต่าง ๆ และสามารถพัฒนาฟังก์ชันเพิ่มเติมได้
- 9.2 แอปพลิเคชันจะสามารถจำแนกชนิดของผักและผลไม้ได้ โดยอิงจากเทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) ซึ่งช่วยให้ผู้ใช้งานสามารถระบุชนิดของผักและผลไม้ได้
- 9.3 ช่วยเพิ่มประสิทธิภาพในการตัดสินใจเลือกซื้อผักและผลไม้ เนื่องจากมีข้อมูลและคำแนะนำ ส่งผลให้ผู้ใช้งานสามารถตัดสินใจเลือกซื้อผักและผลไม้ได้อย่างมีประสิทธิภาพมากขึ้น

10. ข้อจำกัดของโครงการ (Research Limitations)

10.1 ข้อจำกัดด้านคุณภาพของข้อมูล

- 10.1.1 ลักษณะของผักและผลไม้ที่มีความคล้ายคลึงกัน อาจทำให้เกิดความสับสนในการจำแนกประเภท หากโมเดลไม่ได้รับการฝึกฝนด้วยข้อมูลที่แสดงถึงความแตกต่างที่ชัดเจนระหว่างชนิดที่มีความคล้ายกัน โมเดลอาจจะทำการทำนายผิดพลาดได้

10.2 ข้อจำกัดด้านสภาพแวดล้อมในการถ่ายภาพ

- 10.2.1 ความแตกต่างในสภาพแวดล้อมในการถ่ายภาพ เช่น แสงที่แตกต่าง การถ่ายภาพในที่ร่มหรือกลางแจ้ง และมุมการถ่ายที่หลากหลาย อาจมีผลต่อคุณภาพของภาพที่นำไปในโมเดล ซึ่งอาจทำให้โมเดลมีการทำนายที่ไม่แม่นยำ

11. สิ่งที่จะคาดว่าจะทำต่อในอนาคต (Future Work)

- 11.1 ขยายขอบเขตของข้อมูลและการฝึกโมเดล โดยการเพิ่มจำนวนและประเภทของผักและผลไม้ในชุดข้อมูล เพื่อให้ครอบคลุมรายการมากขึ้น รวมถึงการรวบรวมข้อมูลในสภาพแวดล้อมที่หลากหลาย เช่น แสงที่ต่างกันหรือมุมกล้องที่ไม่เหมือนกัน
- 11.2 การพัฒนาอัลกอริทึมการทำนายให้ดียิ่งขึ้น โดยการปรับปรุงโมเดลให้มีประสิทธิภาพสูงขึ้น เช่น การใช้เทคนิคการเรียนรู้เชิงลึกขั้นสูง (Deep Learning) หรือการผสมผสานการเรียนรู้ผ่านการถ่ายโอน (Transfer Learning) ซึ่งสามารถช่วยลดเวลาการฝึกฝนและเพิ่มความแม่นยำในการจำแนกประเภทผักและผลไม้ได้อย่างมีประสิทธิภาพ
- 11.3 การบันทึกและการจัดเก็บประวัติการทำนาย เพิ่มฟังก์ชันที่ให้ผู้ใช้งานใช้ดูประวัติการสแกน รวมถึงรายการผักและผลไม้ที่ถูกสแกนพร้อมรูปภาพและรายละเอียด เช่น วันที่และเวลาที่ทำการสแกน ชื่อผักหรือผลไม้ที่ถูกสแกน ผลลัพธ์การจำแนกประเภท รวมถึงรูปภาพที่ถูกสแกน ซึ่งสามารถนำมาประยุกต์ใช้ในการวิเคราะห์และปรับปรุงการทำงานของระบบในอนาคต



12. เอกสารอ้างอิง (References)

- [1] N. Phongchit, “Convolutional Neural Network (CNN) คืออะไร,” Medium, 2018. [ออนไลน์]. เข้าถึงได้ที่: <https://medium.com/@natthawatphongchit/>.
- [2] S. Kanoktipsatharporn, “Convolutional Neural Network คืออะไร ภาษาไทย ตัวอย่างการทำงาน CNN, ConvNet กับชุดข้อมูล MNIST,” Bualabs, 2019. [ออนไลน์]. เข้าถึงได้ที่: <https://www.bualabs.com/archives/2461/what-is-convolutional-neural-network-cnn-convnet-mnist-deep-learning-convnet-ep-1/>.
- [3] A. Dertat, “Applied Deep Learning - Part 4: Convolutional Neural Networks,” Towards Data Science, 2017. [ออนไลน์]. เข้าถึงได้ที่: <https://towardsdatascience.com/applied-deep-learning-part-4-convolutional-neural-networks-584bc134c1e2>.
- [4] M. S. Ali, “Flattening CNN layers for Neural Network and basic concepts,” Medium, 2022. [ออนไลน์]. เข้าถึงได้ที่: <https://medium.com/@muhammadshoaibali/flattening-cnn-layers-for-neural-network-694a232eda6a>.
- [5] B. Wang, “Loss Functions in Machine Learning,” The Startup, 2021. [ออนไลน์]. เข้าถึงได้ที่: <https://medium.com/swlh/cross-entropy-loss-in-pytorch-c010faf97bab>.
- [6] X. Fang, “Understanding deep learning via backtracking and deconvolution,” Big Data, vol. 5, no. 3, pp. 174-185, 2017. DOI: 10.1186/s40537-017-0101-8.
- [7] S. Kanoktipsatharporn, “Normalization คืออะไร ปรับช่วงข้อมูล Feature Scaling ด้วยวิธี Normalization,” BUALABS, 2019. [ออนไลน์]. เข้าถึงได้ที่: <https://www.bualabs.com/archives/2100/what-is-normalization-feature-scaling-rescaling-normalization-standardization-feedforward-train-machine-learning-preprocessing-ep-2/>.
- [8] P. Gatchalee, “Confusion Matrix เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย ใน Machine Learning,” Medium, 2019. [ออนไลน์]. เข้าถึงได้ที่: <https://medium.com/@pagongatchalee>.
- [9] K. Satangmongkol, “K-Fold Cross Validation พร้อมโค้ดตัวอย่างใน R,” Datarockie, 2019. [ออนไลน์]. เข้าถึงได้ที่: <https://datarockie.com/blog/k-fold-cross-validation/comment-page-1/>.
- [10] Y. Hosni, “Maximizing the Impact of Data Augmentation: Effective Techniques and Best Practices,” Towards AI, 2023. [ออนไลน์]. เข้าถึงได้ที่: <https://pub.towardsai.net/maximizing-the-impact-of-data-augmentation-effective-techniques-and-best-practices-c4cad9cd16e4>.
- [11] พิมพ์ ชีวาประกอบกิจ, “การปรับปรุงประสิทธิภาพในการจำแนกภาพด้วยโครงข่ายประสาทแบบคอนโวลูชันโดยใช้เทคนิคการเพิ่มภาพ,” TNI Journal of Engineering and Technology, vol. 7, no. 1, pp. 1-15, 2562.
- [12] A. Kausar, M. Sharif, J. Park, and D. R. Shin, “Pure-CNN: A framework for fruit images classification,” in 2018 International Conference on Computational Science and Computational Intelligence (CSCI), pp. 82-87, 2018. DOI: 10.1109/CSCI46756.2018.00082.
- [13] N. Purnama et al., “Comparison of CNN transfer learning in detecting superior local fruit types in Bali,” INSYST Journal, vol. 6, no. 1, pp. 39-49, 2024. DOI: 10.52985/insyst.v6i1.389.



- [14] H. Björgvinsdottir and R. Seibold, “Face recognition based on embedded systems,” Master’s thesis, Lund University, Centre for Mathematical Sciences, Lund, Sweden, 2016. [ออนไลน์]. เข้าถึงได้: <https://lup.lub.lu.se/student-papers/search/publication/8883824>.
- [15] R. Pathak and H. Makwana, “Classification of fruits using convolutional neural network and transfer learning models,” Journal of Management Information and Decision Sciences, vol. 24, no. S3, pp. 1-12, 2021.
- [16] ชุตติมา สุขสมัย, ไกรรุ่ง เสงพระพรหม, และ เกล้ากัลยา ศิลลาจันทร์, “การเปรียบเทียบประสิทธิภาพการแปลงข้อมูลที่มีผลต่อการจำแนกข้อมูลของการอนุมัติสินเชื่อของลูกค้าธนาคารด้วยเทคนิคเหมืองข้อมูล,” นครปฐม, 2565. [ออนไลน์]. เข้าถึงได้: <https://publication.npru.ac.th/bitstream/123456789/1672/1/npru-91.pdf>.
- [17] ศุภกิตต์ ฉีดฉายและ ประเมศร์ บ่อแก้ว, “แอปพลิเคชันจำแนกสายพันธุ์ที่พบในไทยด้วย Deep Learning,” วิทยานิพนธ์ปริญญาตรี, มหาวิทยาลัยมหาสารคาม, 2566.
- [18] BornToDev, “เรียน Dart แบบก้าวกระโดด,” [ออนไลน์]. สืบค้น 21 กรกฎาคม 2024, จาก <https://www.borntodev.com/2020/04/11/เรียน-dart-แบบก้าวกระโดด/>.
- [19] AWS, “Python คืออะไร,” [ออนไลน์]. สืบค้น 21 กรกฎาคม 2024, จาก <https://aws.amazon.com/th/what-is/python/>.
- [20] Skooldio, “Deep learning with PyTorch,” [ออนไลน์]. สืบค้น 22 กรกฎาคม 2024, จาก <https://www.skooldio.com/courses/deep-learning-with-pytorch>.
- [21] Amazon Web Services, “Django คืออะไร,” [ออนไลน์]. เข้าถึงได้: <https://aws.amazon.com/th/what-is/django/>.
- [22] Hizokaz, “มาทำความรู้จักกับ Flutter กันเถอะ,” Medium, 2024. [ออนไลน์]. สืบค้น 23 กรกฎาคม 2024, จาก <https://medium.com/@hizokaz/flutter-4dca2ad634bd>.
- [23] WebDodee, “Visual Studio Code หรือ VS Code คืออะไร ทำอะไรได้บ้าง,” [ออนไลน์]. เข้าถึงได้: <https://webdodee.com/what-is-visual-studio-code-and-how-to-use>.
- [24] Boy RealLife, “Android Studio คืออะไร?” [ออนไลน์]. สืบค้น 22 กรกฎาคม 2024, จาก <https://medium.com/@boyreallife/android-studio-lab-3sb04-4202ceff7167>.
- [25] AppMaster, “PostgreSQL คืออะไร,” [ออนไลน์]. สืบค้น 21 กรกฎาคม 2024, จาก <https://appmaster.io/th/blog/postgresql-khuue-aair>.
- [26] Novelbi1, “Google Colab คืออะไร?” [ออนไลน์]. สืบค้น 15 สิงหาคม 2024, จาก <https://www.novelbiz.co.th/google-colab/>.
- [27] True Digital Academy, “รู้จัก 'Figma' Tool ออกแบบ Web/App ที่ดีไซน์เนอร์ทั่วโลกเลือกใช้,” 2023. [ออนไลน์]. เข้าถึงได้: <https://www.truedigitalacademy.com/blog/get-to-know-figma>.
- [28] Seven Peaks, “Postman: เครื่องมือทดสอบ,” [ออนไลน์]. เข้าถึงได้: <https://sevenpeakssoftware.com/th/blog/postman-testing-tools-recommendations-and-how-to-use/>.
- [29] N. Phongchit, “Convolutional Neural Network (CNN) คืออะไร,” Medium, 2018. [ออนไลน์]. สืบค้น 25 กรกฎาคม 2024, จาก <https://medium.com/@natthawatphongchit/>.



- [30] P. Bee, “The concept of dropout in the deep neural net vs implementation,” Boobee, 2019. [ออนไลน์]. สืบค้น 8 พฤษภาคม 2024, จาก <https://medium.com/boobeejung/the-concept-of-dropout-in-the-deep-neural-net-vs-implementation-67a7d46a0f75>.
- [31] K. Satangmongkol, “K-Fold Cross Validation พร้อมโค้ดตัวอย่างใน R,” Datarockie, 2019. [ออนไลน์]. สืบค้น 15 พฤศจิกายน 2024, จาก <https://datarockie.com/blog/k-fold-cross-validation/comment-page-1/>.
- [32] KKLoft, “Convolutional Neural Networks (CNN): สร้าง Model เพื่อทำ Image Classification ด้วย TensorFlow,” Medium, 2020. [ออนไลน์]. เข้าถึงได้ที่: <https://medium.com/@app.kkloft/convolutional-neural-networks-cnn->.
- [33] Paul & Mona. (2024, October 1). *Thai Fruits: 20 Delicious and Exotic Fruits in Thailand*. Toast to Thailand. <https://toasttothailand.com/things-to-do/exotic-thai-fruits/>
- [34] JB & Renée. (2023, January 12). *Thai Fruits: 20 Delicious and Exotic Fruits in Thailand*. Will Fly for Food. <https://www.willflyforfood.net/thai-fruits/>



โครงการวิทยาการคอมพิวเตอร์ ประจำปีการศึกษา 2567
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
คณะศิลปศาสตร์และวิทยาศาสตร์ มหาวิทยาลัยเกษตรศาสตร์ วิทยาเขตกำแพงแสน

ภาคผนวก



สรรพคุณของผักและผลไม้

ตาราง ภาคผนวก 1 รายละเอียดสรรพคุณของผักและผลไม้

ชนิด	สรรพคุณ	แหล่งอ้างอิง
มะระขี้นก (Bitter Gourd)	ช่วยลดระดับน้ำตาลในเลือด เสริมสร้างภูมิคุ้มกัน ลดอาการอักเสบ และมีสารต้านอนุมูลอิสระสูง	กรมการแพทย์แผนไทยและการแพทย์ทางเลือก
กะหล่ำปลี (Cabbage)	ช่วยบำรุงหัวใจ ลดความเสี่ยงของมะเร็ง ปรับสมดุลระบบย่อยอาหาร มีวิตามิน C และไฟเบอร์สูง	กรมอนามัย กระทรวงสาธารณสุข
กะหล่ำดอก (Cauliflower)	ช่วยบำรุงกระดูก ป้องกันมะเร็ง บำรุงหัวใจ เสริมภูมิคุ้มกัน มีสารต้านอนุมูลอิสระ	สถานีสสุขภาพ
หัวไชเท้าขาว (White Radish)	ช่วยบำรุงระบบย่อยอาหาร ลดความดันโลหิต ช่วยขับปัสสาวะและล้างพิษ มีวิตามิน C สูง	สำนักงานเกษตรและสหกรณ์
น้อยหน่า (Custard Apple)	ช่วยบำรุงสายตา เสริมสร้างภูมิคุ้มกัน ลดอาการปวดข้อ อุดมไปด้วยวิตามิน C, B6, และโพแทสเซียม	ข้อมูลพืชสมุนไพร คณะเภสัชศาสตร์ มหาวิทยาลัยศิลปากร
แก้วมังกร (Dragon Fruit)	ช่วยบำรุงผิวพรรณ ลดน้ำหนัก ป้องกันมะเร็ง เสริมสร้างระบบขับถ่าย มีไฟเบอร์สูง	สำนักงานกองทุนสนับสนุนการสร้างเสริมสุขภาพ
มังคุด (Mangosteen)	ช่วยลดการอักเสบ ต้านอนุมูลอิสระ บำรุงผิวพรรณ ช่วยเสริมสร้างภูมิคุ้มกัน	กรมการแพทย์แผนไทยและการแพทย์ทางเลือก
เงาะ (Rambutan)	ช่วยบำรุงผิวพรรณ ลดน้ำหนัก ปรับสมดุลของร่างกาย บำรุงเส้นผม มีวิตามิน C และแมกนีเซียม	ศูนย์วิทยบริการเพื่อส่งเสริมการเกษตร
สละ (Salak)	ช่วยบำรุงสายตา บำรุงกระดูก ลดน้ำตาลในเลือด บำรุงผิวพรรณ มีสารต้านอนุมูลอิสระ	ศูนย์วิทยบริการเพื่อส่งเสริมการเกษตร